FAKULTA MECHATRONIKY, INFORMATIKY A MEZIOBOROVÝCH STUDIÍ <u>TUL</u>



Diplomová práce

Návrh jazyka odvozeného z C a implementace nástrojů pro překlad

Studijní program: B0613A140005 – Informační technologie

Studijní obor: Aplikovaná informatika Autor práce: Maxim Osolotkin

Vedoucí práce: Ing. Lenka Koskova Třísková Ph.D.

Liberec 2025

Tento list nahraďte originálem zadání.

Prohlášení

Prohlašuji, že svou diplomovou práci jsem vypracoval samostatně jako původní dílo s použitím uvedené literatury a na základě konzultací s vedoucím mé diplomové práce a konzultantem.

Jsem si vědom toho, že na mou diplomovou práci se plně vztahuje zákon č. 121/2000 Sb., o právu autorském, zejména § 60 – školní dílo.

Beru na vědomí, že Technická univerzita v Liberci nezasahuje do mých autorských práv užitím mé diplomové práce pro vnitřní potřebu Technické univerzity v Liberci.

Užiji-li diplomovou práci nebo poskytnu-li licenci k jejímu využití, jsem si vědom povinnosti informovat o této skutečnosti Technickou univerzitu v Liberci; v tomto případě má Technická univerzita v Liberci právo ode mne požadovat úhradu nákladů, které vynaložila na vytvoření díla, až do jejich skutečné výše.

Současně čestně prohlašuji, že text elektronické podoby práce vložený do IS STAG se shoduje s textem tištěné podoby práce.

Beru na vědomí, že má diplomová práce bude zveřejněna Technickou univerzitou v Liberci v souladu s § 47b zákona č. 111/1998 Sb., o vysokých školách a o změně a doplnění dalších zákonů (zákon o vysokých školách), ve znění pozdějších předpisů.

Jsem si vědom následků, které podle zákona o vysokých školách mohou vyplývat z porušení tohoto prohlášení.

5. 4. 2025 Maxim Osolotkin

Návrh jazyka odvozeného z C a implementace nástrojů pro překlad

Abstrakt

Klíčová slova: programovací jazyk, překladač

Design of a C-derived language and compiler tools implementation

Abstract

 $\textbf{Keywords:} \ \ \text{programming language, compiler}$

Poděkování

Obsah

	Sezn	am zkratek	10									
Ú	vod		11									
1	Pře	kladač	12									
	1.1	Přechodná reprezentace	12									
	1.2		14									
		1.2.1 Lexikální a syntaktická analýza	15									
			15									
		1.2.3 Převod do finální podoby	16									
	1.3	Cross-Compilation	17									
2	Gra	matiky	18									
	2.1		19									
3	Vývojové nástroje 2											
	3.1	Zvýraznění kódu	21									
		3.1.1 Dokumentace	22									
	3.2	Language server protocol	22									
	3.3	Ladicí program	23									
		3.3.1 Ladicí informace	23									
		3.3.2 Integrace ladicích programu	24									
4	Návrh jazyka 2											
	4.1	Existující řešení	25									
		4.1.1 C++	26									
		4.1.2 D	26									
		4.1.3 Zig	27									
		4.1.4 Odin	28									
	4.2	Vstupní bod programu	29									
	4.3	Alokace	29									
	4.4	Komentáře	30									
	4.5	Pole	30									
		4.5.1 Délka pole	30									
		4.5.2 Typy poli	31									
		4.5.3 Práce s polem	32									
	4.6	Řetězce	33									

Se	znan	n literatury	63
6	Záv	ěr	62
	5.9	Spravá chyb a logovaní	60
	5.8	1	59
	. .	V I	58
		1	58
			58
	5.7		57
	5.6	1	56
	5.5		52
		<i>y</i> 1	51
		1 ,	50
		5.4.1 Prace s paměti	50
	5.4	Parsing	49
	5.3	AST	48
	5.2	Uživatelské rozhrání	47
	5.1	Strukturá	46
5	Imp	olementace kompilatoru	46
	4.12	Compile-time exekuce	44
		4.11.1 custom alloc	44
	4.11		43
		-	40
			40
	4.10		39
	1.0		39
	4.9		37
	4.8	0 1	36
	4.7	1	36
			34 35
		4.6.1 UTF-8	34

Seznam obrázků

Obrázek 1.1:Struktura	překladače																						1	4
-----------------------	------------	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	---	---

Seznam zdrojových kódu

Seznam zkratek

TUL Technická univerzita v Liberci

IR Intermediate Representation

IL Intermediate Language

GCC GNU Compiler Collection

JVM Java Virtual Machine

JIT Just-In-Time (compilation)

CIL Common Intermediate Language
CLI Common Language Infrastructure

AOT Ahead-Of-Time

IDE Integrated Development Environment

API Application Programming Interface

VS Code Visual Studio Code

Vim Vi IMproved

JSON JavaScript Object Notation

HTML HyperText Markup Language

PDB Program Database

DWARF Debugging With Arbitrary Record Formats

GDB GNU Debugger

LLDB Low-Level Debugger

ELF Executable and Linkable Format

Úvod

Dnes, v době, kdy člověk se spíš zeptá, zda něco "umí" JavaScript, než zda na tom "běží" Doom, zůstává jazyk C fundamentálním pilířem softwaru.

Ačkoli jazyk C mi vždy imponoval, malokdy jsem se v něm našel dělat vlastní projekty. Obvykle jsem sahal po jazyku C++, který nabízel některé moderní prvky, jež mi ve standartním C scházely. Nicméně, programování v C++ se vždy pojilo s frustraci narůstající s mírou použitých knihoven. Proto jsem si položil otázku, zda existuje alternativa – jazyk spojující filozofii C a odražející požadavky dnešní doby.

Odpovědí na tuto otázku byly jazyky Odin a Zig, které představují moderni alternativy k C. Nicméně jejich syntaxe se od C odklání směrujíc vice implicitním směrem v duchu Go. Pro mně však byla klíčová explicitní syntaxe C, která jasně specifikuje deklarace proměnných a vytvaří tím dojem jednoduchého a čitelného jazyka.

Ve vysledku jsem s těmito řešeními nebyl spokojen a zdálo se mi, že většina alternativ se spíše zaměřuje na nahrazení C++ a bezpečnost než na jednoduchý jazyk s plnou kontrolou nad pamětí, která mě na C tolik oslovila. Proto jsem dospěl k myšlence návrhu vlastního jazyka, což vedlo k napsání této práce.

V úvodní častí prace se dotknu teoretických základů týkajících se překladačů a programovacích jazyků a představím možnosti pro tvorbu nástrojů k zajištění podpory vlastního jazyka. Nasledně se budu věnovat samotnému návrhu jazyka, kde kromě zdůvodnění jednotlivých rozhodnutí se budu odkazovat na jiné jazyky a diskutovat jejich řešení. V závěru práce se zaměřím na konkrétní aspekty implementace překladače.

1 Překladač

Překladačem, nebo též kompilatorem, se nazve program, který převádí vstupní text do výstupního textu zachovávající význam, kde oba texty jsou zapsané nějakým jazykem. Samotný proces převodu se nazývá překladem nebo take kompilací. V kontextu programovacích jazyků jde o převod zdrojového kódu do jiného programovacího jazyka nebo přímo do strojového kódu.

Existence kompilátoru je zásadní pro libovolný programovací jazyk, protože z podstaty věci finálním cílem je dostat program reprezentující zdrojový kód běžící na nějakém stroji, či v nějakém virtuálním prostředí.

Za cíl se také může klást i návrh jazyka čistě pro zápis programů. Ovšem, pokud neexistuje nástroj pro překlad tohoto zápisu do jazyka, který ve výsledku je schopen být přeložen do spustitelné podoby, onen zápis nemá žádnou technickou relevanci.

Často tedy dochází k případům, kdy pojmy kompilátor a jazyk splyvají nebo se zaměňují. Kdy se při použití názvu jazyka implicitně bere i na mysl konkrétní kompilátor, např. Go. Nebo kdy se naopak místo názvu jazyka používá název kompilátoru, např. Turbo Pascal.

Protože překladač je jen program jako každý jiný, může být napsán v libovolném programovacím jazyce a přeložen odpovídajícím kompilátorem. Dokonce může být napsán v jazyce, který sám překládá, a přeložen sám sebou — tento proces se nazývá bootstrapping. To vede k problému "kuřete a vejce", který má v tomto případě jasné řešení, protože ve vysledku existuje stroj schopný vykonávat určitou sadu instrukcí. Typo instrukce vlastně tvoří jazyk, který je spustitelný a dá se vnímat jako nejtriviálnější kompilátor pro daný stroj.

1.1 Přechodná reprezentace

Programovací jazyk slouží jako abstrakce semantiky programu a jeho skutečné podoby na konkrétním hardwaru a po případě operačním systému. Je zřejmé, že takto lze proložit chtěné množství vrstev abstrakcí před překladem do strojového kódu. Obecně však dává smysl pouze jedna další vrstva, kdy se jazyk přeloží nejprve do tzv. přechodné reprezentace (IR — intermediate representation), a až poté do kódu pro konkrétní hardware. Účelem této abstrakce je vytvoření rozhraní mezi výrobci hardwaru a tvůrci jazyků. Část určená pro překlad do IR se označuje jako front-end

a část převádějící IR do spustitelného kódu jako back-end.

Je nutno podotknout, že jak back-end, tak i front-end jsou samostatné celky, kkteré jsou implementovány pro specifické problémy nebo potřeby. Proto i jejich implementace mohou obsahovat vlastní front-endy a back-endy. Výrobci hardwaru či jazyků tak nemusí přímo implementovat podporu IR, ale mohou využít rozhraní existujících obecných back-endů a front-endů.

Samotná IR může být reprezentována buď jako rozhraní a objekty či struktury v programovacím jazyce, nebo přímo jako jazyk, tzv. mezijazyk (IL – intermediate language).[1]

Dále se specifikuje pár ukázek IR s krátkým popisem a ukázkou reprezentace následující jednoduché C funkce:

```
unsigned add1(unsigned a, unsigned b) {
   return a+b;
}
```

LLVM IR Forma široce využívaná v rámci LLVM nástrojů, především pro účely optimalizace a kompilace. Jedná se o jazyk, který se nachází na pomezí C a assemblerem. Může být jak v standartní textové podobě, tak i přímo implementován v paměti programu.[2]

```
define i32 @add1(i32 %a, i32 %b) {
entry:
    %tmp1 = add i32 %a, %b
    ret i32 %tmp1
}
```

GCC GIMPLE Jedna z mezireprezentací využívaných GCC, která je klíčová při optimalizacích a generování kódu. Výrazy převádí do tříadresného formátu zjednodušujíc tím analyzu a transformaci kodu.[3]

```
unsigned int add1(unsigned int a, unsigned int b) {
    unsigned int _tmp;
    _tmp = a + b;
    return _tmp;
}
```

Java bytecode Jedná se o instrukční sadu JVM (Java Virtual Machine). Název je odvozen od skutečnost, že každá instrukce je reprezentována jedním bytem. Bytecode je využíván JVM k JIT (viz 1.2.3) kompilaci. Lze jej tedy spustit spustit na jakékoli platformě, na které je implementován příslušný JVM.[4]

```
.method public static add1(II)I
.limit stack 2
.limit locals 2
iload_0
iload_1
iadd
ireturn
.end method
```

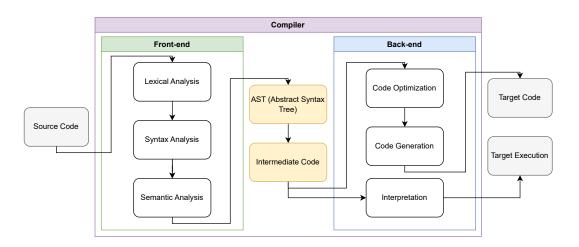
CIL Jedná se o zkratku pro Common Intermediate Language. Představuje obdobu Java bytecode, vyvinutou společností Microsoft. Pro spuštění CIL je nezbytná platforma podporující nějakou implementaci Common Language Infrastructure (CLI), jako je například .NET.[5]

```
.method uint32 add1(uint32 a, uint32 b) cil managed {
   .maxstack 2
   ldarg.0
   ldarg.1
   add
   ret
}
```

C Samotný jazyk C může rovněž sloužit jako přechodná reprezentace, přestože nebyl pro to navržen[1]. Jedná se o jazyk s nízkou úrovní abstrakce využívaný v různých operačních systémech. Existuje pro něj tak velký výběr kompilátorů pro různé platformy a rozsáhlé množství dalších vývojových nástrojů.

1.2 Konstrukce překladače

Samotný překlad se může rozdělit do pár základních kroků. Nejprve je provedena lexikální a syntaktická analýza, kde čirý sled textu je převedena na abstraktní reprezentaci. Následně je tato reprezentace zvalidována podle příslušných sémantických pravidel. Validní reprezentace je následně převedena do zvolené IR nebo přímo do spustitelné podoby. [6, 7]



Obrázek 1.1: Struktura překladače

Obecně překlad může obsahovat více kroků, které se dále mohou štěpit. Nicméně, vytknuté tři kroky jsou nezbytné pro jakýkoliv překlad. Možnou vizualizaci struktury překladače ilustruje obrázek [1.1].

1.2.1 Lexikální a syntaktická analýza

Cílem je převést zdrojový kód na základě gramatiky jazyka do abstraktní datové struktury v paměti překladače. Tato struktura je často reprezentována stromem, jelikož stromová struktura přirozeně odpovídá gramatické struktuře jazyka, a nese ustalený název AST (Abstract Syntax Tree).

Zde se nabízí zřejmá abstrakce mezi lexikální a syntaktickou analýzou. Kde modul lexikální analýzy se stará o zpracování vstupního textu a převádí slova na reprezentaci v paměti překladače nazývanou token. Syntaktická analýza pak může se slovy pracovat jako s abstraktními celky. Lexikální část se často nazývá lexer a syntaktická parser.

Zároveň se nabízí smysluplná abstrakce i mezi formální gramatikou jazyka a samotnou lexekalní a syntaktickou analyzou. Možnost formálního popisu jazyka za pomoci jistého standardu gramatiky (viz 2.1) umožňuje i existenci příslušných nástrojů napomáhajících při generaci AST.

Mezi takové nástroje patří třeba YACC a ANTLR.

YACC Neboli Yet Another Compiler-Compiler. Jedna se nástroj umožňující syntaktickou analýzu na základě formalní gramatiky jazyka (pro bližší představení samotného formátu gramatiky viz 2.1). YACC používá specifický formát připominajicí dialekt C. Jednotlivým syntaktickým celkům se dají přiřadit akce (funkce v C), jež se provedou při rozpoznání přislušné syntaktické struktury. Pro lexikální analýzu YACC využivá uživatelem definovanou funkci, přičemž standardně se využívá nástroj Lex. YACC ve výsledku generuje C kód (hlavně yyparse funkci), který se již používá v samotném kompilátoru. [8]

ANTLR Neboli Another Tool for Language Recognition. Jedná se o nástroj umožňující generaci parseru z gramatiky. Kromě generace samotného parseru dokáže ANTLR generovat i tzv. procházeče (visitors a listeners) stromu, které umožňují aplikaci vykonávat vlastní kód. Primárním cílovým jazykem pro generování parseru v ANTLR je Java, ale podporuje generaci i do jiných jazyků, jako C#, Python, Go atd. [9]

1.2.2 Sémantická analýza a Anotace AST

Během sémantické analýzy se provádí kontrola AST a doplňují nebo aktualizují se informace v jeho uzlech. Cílem je získat validní AST reprezentující původní text. Kontrola se může lišit od jazyka k jazyku v závislosti na striktnosti jeho pravidel.

Může se zde provést ověření existence příslušných deklarací vyskytujících se proměnných v příslušných jmenných prostorech; kontrola datových typů proměnných a výrazů; nalezení vhodné funkce v případě přetížení funkcí, a podobně. Kromě validace se zároveň existujícím symbolům přiřazují odkazy na příslušné definice, je-li to relevantní z hlediska struktury navrženého AST. Například uzlu reprezentujícímu proměnnou se přiřadí odkaz na její definici.

1.2.3 Převod do finální podoby

V závěrečné fázi se AST transformuje do patřičné finální podoby. Obecně by pro každý typ uzlu v AST měla existovat odpovídající sekvence instrukcí pro jeho zpracování. Nejpřirozenější způsob je existence funkce pro každý typ uzlu AST, kdy by se volala vždy příslušná funkce při procházení stromu. Ovšem, je to ve výsledku jen obyčejný program, takže implementace může být vždy přizpůsobena konkrétnímu problému.

Způsoby transformace AST v závislosti lze rozdělit v zavisloti na finálním produktu.

- Kód Výsledkem je kód v jiném jazyce, tedy buď v IL, nebo přímo strojový kód. V tomto případě buď překlad končí, anebo se předpokladá, že výsledný kód bude přeložen jiným nástrojem do spustitelné podoby. Může se jednat i o generování skriptů, které jsou pak součástí větších celku, jako jsou třeba herní enginy. Nebo se může jednat i o tzv. transkripci, jako v případě TypeScriptu.
- JIT Ačkoli formálně spadá do předchozí kategorie, samotný koncept JIT kompilace je natolik vyznamný, že stojí za samostatnou zmínku. Zkratka JIT znamená Just-In-Time. Jedná se o metodu kompilace, při které je nejprve generovaná IR reprezentace, která je nasledně předána tzv. JIT kompilátoru. Ten pak přeloží IR do konkrétního strojového kódu mašiny, na které běží.

Důležitým aspektem JIT kompilace je umožnění specifických optimalizací kódu pro danou platformu a také možnost změny kodu za běhu programu. Na rozdíl od klasické, takzvané předčasné (AOT – Ahead-Of-Time) kompilace, která probíhá pouze jednou a pro obecně očekávaný hardware.

Interpretace Namísto generování výsledného kódu lze každý uzel AST přímo interpretovat. Tedy, namísto implementace funkce, jejíž výstupem by byl text v jiném jazyce, se přímo implementuje semantické chování uzlu. Takovéto kompilátory se zpravidla označují za interpretery.

1.3 Cross-Compilation

Někdy je vhodné přeložit program do strojového kódu jiného hardwaru, než na kterém běží kompilátor. Tomuto procesu se říká cross-compilation. Může k tomu docházet v případech, kdy je program vyvíjen na vysoce výkonném stroji s veškerým potřebným prostředím pro rychlou a efektivní práci, avšak vysledný software má odlišné cilové zařízení postradajicí takovou infrastrukturu. Příčinou může být operační systém, nebo i samotný hardware stroje.

Také se jedná o případy, kdy program je překladán i pro jiný operační systém, než na kterém je vyvíjen. Například, Doom byl vyvíjen na počitači NeXT s operačním systémem NeXTSTEP, přestože byl určen pro systémem MS-DOS.

Je zřejmé, že o cross-compilaci má smysl mluvit pouze v případě kompilace do strojového kódu. V ostatních případech se jedná o kód, který je mezivýsledkem (například bytecode) a jeho spuštění závisí na jiném nástroji, který musí být sám přeložen pro cílovou architekturu.

2 Gramatiky

Při návrhu programovacího jazyka hraje důležitou roli samotná syntaxe, která ho z velké části definuje. Syntaxe totiž p5edstavuje jakésí rozhraní mezi člověkem a jazykem, obzvlášť v případě programovacích jazyků, kde se v textových editorech či vývojových prostředích běžně různé syntaktické konstrukce vizualně odlišují. Proto je žadoucí mít možnost ji formálním způsobem popsat, a to jak z teoretického hlediska, tak i z praktického. Definice gramatiky jazyka může byt využítá v různých nástrojích, například, jak již bylo zmíněno, pro syntaktické zvýrazňování.

K definici syntaxe jazyka slouží tzv. formální gramatika. Formální gramatiku můžeme definovat následovně:

Definice 2.1. Formální gramatika G je čtveříce (Σ, V, S, P) , kde:

- Σ je konečná neprazdná množina terminálních symbolů, tzv. terminálů.
- V je konečná neprazdná množina neterminálních symbolů, tzv. neterminálů.
- S je počáteční neterminál.
- P je konečná množina pravidel.

[10]

Terminály jsou dále nedělitelné symboly jazyka. Jsou to například klíčová slova nebo jednotlivá písmena sloužící pro definici proměnných. Neterminály pak představují symboly, které se dále přepisují na jiné sekvence terminálů nebo neterminálů. Neterminál může například reprezentovat binární operátor, který nasledně bude definován pravidly obsahující již terminální symboly jednotlivých binárních operátoru. Prázdný symbol se označuje jako ϵ .

Obecně pravidlo gramatiky můžeme vyjádřit jako zobrazení: ¹

$$\alpha \to \beta,$$
kde $\alpha \in (\Sigma \cup V)^*V(\Sigma \cup V)^*, \ a \ \beta \in (\Sigma \cup V)^*$

Tedy vzorem je posloupnost terminálů a neterminálů obsahující alespoň jeden neterminál. Obrazem pak je libovolná posloupnost terminálů a neterminálů.[10]

Gramatiky lze členit na základě striktnosti pravidel dle tzv. Chomského hierarchie.

¹Hvězdíčka (*) představuje symbol libovolného opakování výrazu, a to i žádného.

Definice 2.2. Necht $G = (\sigma, V, S, P)$ je gramatika, pak:

- G je gramatika typu 0 nebo také neomezená gramatika právě tehdy, když ...
- G je typu 1 nebo také kontextová gramatika právě tehdy, kde pro každé pravidlo $\alpha \to \beta$ z P platí $|\beta| \ge |\alpha|$ a zároveň pravidlo $S \to \epsilon$ se nevyskytuje na pravé straně.
- S je typu 2 nebo také bezkontextová gramatika právě tehdy, když pro každé pravidlo $\alpha \to \beta$ z P platí $|\alpha| = 1$. Neboli, že α je pouze neterminál.
- P je typu 3 nebo také regulární gramatika právě tehdy, když každé pravidlo z P je v jedné z forem:

$$A \to cB, A \to c, A \to \epsilon$$

kde A, B jsou libovolné neterminály a c je terminál.

[10]

Z hlediska programovacích jazyků prakticky se lze omezit na gramatiky bezkontextové.[7]

2.1 Bezkontextová gramatika

Bezkontextovou gramatiku, kromě výše uvedené definice (2.2), lze také definovat na základě samotných pravidel, což bude názornější pro navazující text.

Definice 2.3. Gramatika $G = (\sigma, V, S, P)$ je bezkontextová právě tehdy, když pro každé pravidlo z P platí

$$A \to \gamma$$
,

kde

$$A \in N, \gamma \in (N \cup \Sigma)^*$$

Například, pravidlo pro sestavení goto výrazu v jazyce C může být vyjádřeno ve volné formě třeba následovně

$$goto \rightarrow 'goto' identifier ';'$$

Pravidlo definuje nonterminál goto jako sekvenci terminálu 'goto', následovánou nonterminalem identifier (definováným v jiném pravidle představujícím identifikátor) a zakončeného terminálem ';'.

Definuje-li se pak třeba identifier za pomoci regulárního výrazu následovně

$$identifire \rightarrow [a\text{-}zA\text{-}Z]^+$$

goto pravidlo bude třeba generovat slova jako

goto FooLabel;

```
goto Me;
```

goto UnhandledException;

Je zřejmé, že zápis pravidel může být různorodý. Pro sjednocení zápisu existuje několik standardních notací. Nasleduje přehled několika relevantních notací stručně představených na příkladu s goto příkazem.

BNF Zkratka pro Backus–Naur forma.

```
<goto-stmt> ::= "goto" <identifier> ";"
<identifier> ::= <letter> <letters>
<letters> ::= <letter> <letters> | \epsilon
<letter> ::= "a" | "b" | ... | "Z"
```

EBNF Rozšířená (Extended) Backus–Naur forma. Existuje několik verzí a má svůj ISO standard.

```
goto-stmt = "goto", identifier, ";";
identifier = letter, { letter };
letter = "a".."z" | "A".."Z";
```

YACC notace Bližší seznámení s YACCem muže byt nalézeno zde: 1.2.1.

```
goto_stmt : KW_GOTO identifier ';' { .. };
```

Složené závorky ohraničují C kód, který se provede při úspěšném parsingu přislušných syntaktických elementů. Neterminály a terminály z příslušných pravidel jsou přístupné za pomocí symbolu \$. Například \$ označuje proměnnou samotného rozpoznaváného pravidla, \$1 proměnnou prvního symbolu pravé strany (KW GOTO v případě pravidla goto), \$2 respektive druhého atd.

Definice identifier je pak součástí jiného programu zvaného Lex, na výstup kterého YACC spoléhá.

```
identifier : [A-Za-z]+
```

ANTLR notace Bližší informace o ANTLRu lze nalézt zde: 1.2.1.

```
goto_stmt : 'goto' identifier ';';
identifier : [a-zA-Z]+;
```

3 Vývojové nástroje

Kromě samotného překladače se při práci s programovacím jazykem běžně využívají různé nástroje usnadňující vývoj.

Základem je textový editor, bez kterého by nebylo možné samotný zdrojový kód v celku psát. Samotné editory pak, často prostřednictvím pluginů, umožňují přidávat podporu různých programovácích jazyků. Mezi takové populární editory patří například VS Code nebo Vim/Neovim. Lze je tedy využít jako platformu pro tvorbu jakéhosi integrovaného vývojového prostředí (IDE) pro vlastní jazyk.

Pluginy, nebo také Extensions, se ve VS Code dají standardně psát za pomoci Type-Scriptu či JavaScriptu. Jako v prohlížečích, je zde i možnost využití WebAssembly. Lze tedy využít i jiný jazyk, který by šel do WebAssembly zkompilovat, jako třeba Rust nebo C++. Ke komunikaci s editorem je zde VS Code API, které umožňuje přístup k elementům uživatelského rozhraní editoru, poslouchání různých eventů, přístup k debuggeru atd. Všechny pluginy se pak dají nahrát do jednotného oficiálního marketplace, kde budou dostupné uživatelům a umožní automatické aktualizace.[11, 12]

V případě Neovim je zde kromě klasických možností využití Vimscriptu, jak v případě Vim, dostupná možnost skriptování za pomoci integrovaného Lua script enginu[13]. Celé API editoru Neovim je pak přístupné prostřednictvím jazyka Lua. Lze tedy přímo přistupovat k bufferům a měnit rozhraní celého editoru. Pluginy jsou ve své podstatě jen zdrojové kódy, které se načitají při spuštění editoru na základě konfigurace. Obvykle za využití nějakého správce pluginů (napřiklad lazy.nvim), který umožní načtení složky s pluginem jedním řádkem. Standardním způsobem distribuce pluginů je pak git repozitář se samotným kódem pluginu, odkaz na který uživatel předá správci pluginů. Takto uživatel bude moct i jednodušé ziskávát aktualizace pluginu.

3.1 Zvýraznění kódu

Za základní standardní vlastnost se může klást zvýraznění kódu, které je dnes prakticky zřejmostí.

K definici vlastního zvýrazňování se v případě VS Code využívá TextMate, který umožňuje definovat vlastní gramatiku v JSON souboru za využití regulárních vý-

razů[14]. V případě Vim se používá vlastní formát definice zvýraznění syntaxe, který rovněž podporuje využití regulárních výrazu.[15]

Oba tyto přístupy využívají tak či onak prohledávání a parsování zdrojového kódu pro zvýraznění. Existuje však i jiný přístup, který je v praxi rychlejší a přesnější, a to za využití LSP (viz 3.2). Většinou totiž LSP je i tak aktivní a poskytuje napřiklad funkci doplňování slov. Tedy editor už obsahuje informaci o všech symbolech a jejich roli v jazyce. Oba vybrané editory mají vestavěnou podporu LSP[16, 17].

3.1.1 Dokumentace

Kromě zvýraznění synatxe v textových editorech je někdy potřeba mít možnost zvýraznění kódu ve statických dokumentech. Například jako dokumentace, která je nezbytná pro popis semantiky jazyka uživateli.

V takovémto případě lze využít například nástroje Shiki[18]. Jedná se o JavaScript knihovnu, která využívá TextMate gramatiky k generaci zvýrazněného výstupu. V základu Shiki umí generovat výstup jako HTML. Klasické užití je pak napsání drobného skriptu v NodeJS, který by procházel HTML dokument a nahrazoval vybrané elementy, např. code, výstupem z Shiki. Výsledný HTML dokument pak neobsahuje žádný JavaScript běhový kód. Obdobným způsobem je generována dokumentace obsažená v příloze.

V případě Vim syntaxe je zde možnost využití jeho samotného ke generování HTML z kódu. Je zde opět potřeba napsánt skript, který by automaticky procházel HTML soubor a přepisoval zdrojový kód.

```
vim -c 'syntax on' -c 'T0html' -c 'wq' myfile.html
```

Bohužel, zde nejsou výrazné nástroje, které by umožnily využití Vim syntaxe pro generování zvýrazněného výstupu, jako v případě TextMate gramatiky. Pro využití v HTML dokumentech existuje opce využití vim.js[19], tedy portu Vim pro prohlížeče, který by mohl provádět zvýraznění syntaxe za běhu. Ovšem využití tohoto řešení jen pro zvýraznění kódu je zbytečně náročné.

3.2 Language server protocol

Language server protocol, zkráceně LSP. Jedná se o protokol využívaný pro komunikaci mezi jazykovým serverem a klientem, kterým může být IDE nebo textový editor. Jazykový server poskytuje klientovi informaci o zdrojovém kódě z hlediska sémantiky a syntaxe jazyka. Smyslem je nabídnout rozhraní mezi programem nabízejícím syntaktickou a semantickou informaci o kódu a vývojovým nástrojem.

V základu k implementaci lze použít část kódu ze samotné implementace kompilátoru, či dokonce celé moduly. Práce serveru je totíž od části shodná až do fáze sémantické analýzy. Nicméně, kompilátor může obvykle ukončit překlad při první

zjištěné chybě. LSP by naopak měl být schopen překladát i neúplně správný syntaktický a semantický kód a poskytovát informace o tom, co se podařilo převést do AST. Navíc, LSP by měl fungovat v reálném čase obnovující informaci o kódu po každém vstupu uživatele. Vývoj LSP tedy není triviálním úkolem i za podmínky existence překladače, jelikož jak překladač, tak i LSP vyžadují vyskou rychlost zpracování dat, ovšem jejich potřeby se protiřečí.

bla bla bla

3.3 Ladicí program

Dalším klíčovým nástrojem pro vývoj programů je ladicí program. Zde opět lze využít vybraných textových editorů jako platformy. Ovšem psaní vlastního ladicího programu není zcela žádoucí, jelikož je to další aplikace, která se bude muset s jazykem vyvíjet a udržovat. Je proto výhodnější využít již existujících řešení prostřednictvím standardizovaných rozhraní.

3.3.1 Ladicí informace

Ladicí informace je veškerá informace, která není obsažená ve spustitelném souboru, ale je napomocná debuggeru k propojení zdrojového kódu a konečných instrukcí. Debugger pak může umět například krokovat zkompilovaný program ve zdrojovém kódu, zobrazovat hodnoty proměnných atd.[20]

Pro jazyk překladaný do strojového kódu pro účely ladění stačí mít vysledný program jako spustitelný soubor a k němu vygenerovanou debug informaci. První problém řeší samotný kompilátor, a tedy zbývá vyřešit otázku generace debug informace.

V zásadě existují dva hlavní formáty využívané moderními debuggery, a to PDB a DWARF.[20]

PDB Zkraceno z Program Database. Jedná se o soubory převážně využívané Microsoftem, například pro debugování ve Visual Studio. PDB vnitřně, pro definici samotných debug symbolů, využívá formátu CodeView. V rámci Windowsu existuje API, které umožňuje získání informací z PDB souboru bez znalostí formátu. [21]

DWARF Zkraceno z Debugging With Arbitrary Record Formats. Formát využívaný například GDB a LLDB. Převažně pro programy na Linux a macOS. Často se používá v rámci ELF souborů. Standardně býva vestavěn do spustitelného souboru.[22]

Přímočarou možností je vlastnoruční generace těchto souborů. Naštěstí některé backendy umožňují generaci oných symbolů.

V případě LLVM IR lze třeba definovat podrobnější informace o původním kódu za pomoci maker #dbg_value, #dbg_declare a #dbg_assign[20]. Může to vypadat následovně:[20]

```
%i.addr = alloca i32, align 4
#dbg_declare(ptr %i.addr, !1, !DIExpression(), !2)
; ...
!1 = !DILocalVariable(name: "i", ...) ; int i
!2 = !DILocation(...)
```

První řádek zde představuje deklaraci proměnné i typu int32_t. Následující pak přidává oné deklaraci metadata. Dalších řádky specifikují detaily těchto metadata. Lze to použít jak pro generaci PDB, tak i DWARF[20].

Nebo, například při použití C jako IL, lze využít vybraného kompilátoru umožňujícího generaci potřebného formátu. Pro mapování zdrojového kódu na C kód pak lze využít direktivy #line[23], která umožňuje specifikovat číslo řádku a název souboru. Tato direktiva však ovlivňuje pouze bezprostředně následující řádek kódu, což lze řešit generací kódu bez konců řádků a přidáváním jich vždy při použití oné direktivy.

3.3.2 Integrace ladicích programu

Pokud je možné generovat ladicí informaci spolu se spustitelným souborem, lze pro ladění využít libovolného již existujícího ladicího programu, ktery by podporovál přislušný format.

Protože VS Code standardně poskytuje rozhraní pro integraci ladicích programu, lze pouze vytvořit vlastní konfiguraci pro již existující ladicí rozšíření a upravít konfiguraci překladu. Popřípadě lze tuto konfiguraci zabalit i do samostatného rozšíření.

Neovim nemá standardizované rozhraní pro ladicí programy, proto je konfigurace každého ladicího pluginu individuální, jestli je vůbec v konkrétním případě dostupná. Vždy ale lze udělat fork . . .

4 Návrh jazyka

Prvně bych vytvoříl nějakou představu o vizi jazyka a motivaci. Protože v zasadě cílem je přijit s moderní obdobou C, tak by bylo k věci jim i začít.

V jazyce C se mi v zasadě libí jeho jednoduchost, co se napiše, to v podstatě i platí. Neprovádí se v pozadí tucet instrukcí — neobsahuje skrytý tok řízení. Má explicitní syntaxi, která se dá číst. Nabízí možnost příme a volné práce s pamětí, ktera je ve většině jazyku potlačená kvuli bezpečností, ale dodává tu špetku hravostí, kdy se problém vyřeší chytrou, nebo i hloupou, interpretaci paměti.

Je to jazyk, ve kterém je zajímavé programovat, i když ne vždy je vhodným nástrojem pro produkční řešení. Má ale pár zásadních nedostatků, které mně většíniu odradí od jeho využití. Například: samotné sestavení programu je příšerné, neustálá duplicita informace v deklaracích a oddělených definicích, problémy s duplicitními jmény při použití knihoven, makra atd.

Vycházejíc z toho bych tedy viděl proceduralní systemový general purpose jazyk umožňujicí robustní a explicitní compile-time vyhodnocení. Jazyk, který by umožňovat jednoduchou a neomezenou manipulaci s pamětí. Byl čitelný sam o sobě i na úkor osvědčeným postupům. Interpretace kódu po přečtení by měla co nejvíce odpovidat skutečnosti, například: deklarace proměnné by neměla byt ve vychozím připadě konstatní, protože po přečtení kodu, ktery nespecifikuje vlastností deklarce je přirozenější se domnivát, že žadných vlastnotí nenabyva, než že jsou nějaké standardní skryté. Syntaxe by měla byt srozumitelná intuitivně i bez znalostí gramatiky. Tedy, v zasadě, akce spiš interpretovaný slovy než symboly.

Jazyk by neměl přímo plnít nějaky cíl, nebo byt určen specialní sfeře. Jedná se o tvorbu nastroje pro moje vlastní užití, jazyk, ve kterem bych mohl psát vlastní projekty. A tedy i pro jedince, které by měli stejný náhled na věc.

4.1 Existující řešení

Existují jazyky v tom čí jiném smyslu řešicí muj problem. Některé z mého hlediska jsou vskutku skvělé a zajímavé. Ovšem, nenašel jsem se v ních na tolik, abych pak něco nevyčítal. Přijde mi tedy vhodným je představít a vytknout věcí, které jsou odlišné od moji představy.

4.1.1 C++

besprostřední naslednik C, ktery je i často s ním nerozlučně poejn jako C/C++. C++ ponechavá v zakladu C s drobnými změnami a staví na tom v zakladu za pomocí standardní knihovný. C++ tedy dědí i špátné vlastností C, jako jsou například makra a system importu. Nové vlastností často nejsou častí jazyka, ale objekty právě standardní knihovny. Mezi takové patří i základní věci jako pole.

Jazyk obsahuje mnoho různorodých konceptu umožňujících řešit problemy paradigmalně různými způsoby. I když se to může vnímat jako výhoda, a člověk si může vybrát nějakou podmnožinu vlastností, která mu vyhovuje, tak jen zřídka veškerý kod je psán jedním člověkem. Například při práci s knihovnou, která řeší problémy objektově se musí potýkat člověk nepíšící kód objektově. To vede k velmi nekonzistentnímu kódu. I samotná standardní knihovna, která implementuje hodně zásadních vlastností jazyka využívá metaprogramovaní a objekty.

Syntaktický je pak jazyk příšerný, protože po mimo míchání samotných přístupu k programování se míchá i C a C++ kód. To zesložituje vnímání a čitelnost kodu, protože nebí moc jasné co se má dít, a jak C++ objekty nakldaaji s puvodnimi datovými typy a jak je interpretuji.

Ukázka syntaxe – vypočet

4.1.2 D

Jazyk syntaktický blízký C, zjednodušuje koncepty C++ a zbavuje se přímé návazností na C. Tedy importovaní system je řešen za pomoci modulu, podobně jako v Java. Žádná makra, spoleh na compile-time exekucí a genericitu jednodušit koncepty C++ a zbavit Zjednodušený Syntaktický blízký jazyk k C.

Ovšem, je to objektový jazyk s hidden-flow elementy (např try-catch), který jde spíš ve stopách C++ než C. Navíc obsahuje garbage collector, který sice lze zakázat, ale některé vnitřní operace ho stále budou používat.

Ukázka syntaxe – paralelní inicializace poli

```
void main() {
   import std.datetime.stopwatch : benchmark;
   import std.math, std.parallelism, std.stdio;

auto logs = new double[100_000];
auto bm = benchmark!({
      foreach (i, ref elem; logs)
            elem = log(1.0 + i);
   }, {
      foreach (i, ref elem; logs.parallel)
            elem = log(1.0 + i);
   })(100); // number of executions of each tested function
   writefln("Linear_init:_u%s_msecs", bm[0].total!"msecs");
   writefln("Parallel_init:_u%s_msecs", bm[1].total!"msecs");
}
```

4.1.3 Zig

Jedna se o relativně moderní, jednoduchý, procedurální jazyk jdoucí ve stopách C. Jazyk staví na compile-time exekucí mataprogramování nabízejíc široké spektrum možností jejího využití. Neobsahuje skrytý řidicí tok programu. Práce s pamětí je manualní. Překladač obsahuje varianty sestavení, které umožňují provádět doplňujicí bezpečnostní kontorly jak při kompilaci tak i v run-timmu. Navíc je možné sestavovát program cross-kopilaci.

Ve své podstatě se jedná o velmi blizky jazyk mym představám až ná některé drobné věci jako napřiklad, že ukazatel je standardně nenulovatelný. Hlavní vytku mám k syntaxi, která není moc explicitní a využívá až moc symbolu.

Ukazka syntaxe – parsing celých čísel

```
const std = @import("std");
const parseInt = std.fmt.parseInt;
test "parse integers" {
    const input = "123_{\sqcup}67_{\sqcup}89,99";
    const ally = std.testing.allocator;
    var list = std.ArrayList(u32).init(ally);
    // Ensure the list is freed at scope exit.
    // Try commenting out this line!
    defer list.deinit();
    var it = std.mem.tokenizeAny(u8, input, "__,");
    while (it.next()) |num| {
        const n = try parseInt(u32, num, 10);
        try list.append(n);
    }
    const expected = [_]u32{ 123, 67, 89, 99 };
    for (expected, list.items) |exp, actual| {
```

```
try std.testing.expectEqual(exp, actual);
}
```

4.1.4 Odin

Obdobně jak Zig se jedná o moderní analog C. Proceduralní jazyk s jednoduchou a minimalisticou syntaxi. Nabizí pár zajimavých jako třeba kontext viz[]. a vestavené aritmetické programování s poli, a k tomu i maticový typ, ktery umožňuje třeba nasobení matic, matic a poli a pod.

Jako nedostatek bycho vytknul absenci explicitní compile-time exekuce, která je fakticky možná jen při definici konstant. Syntakticky jazyk je relativně implicitni a podobá se jazyku Go. Syntaxe mi přijde vice intuitivní než v připadě Zigu.

Ukazka syntaxe – programování s poli

```
package main
import "core:fmt"
main :: proc() {
        Vector3 :: distinct [3]f32
        a := Vector3\{1, 2, 3\}
        b := Vector3{5, 6, 7}
        c := (a * b)/2 + 1
        d := c.x + c.y + c.z
        fmt.printf("%.1f\n", d) // 22.0
        cross :: proc(a, b: Vector3) -> Vector3 {
            i := a.yzx * b.zxy
            j := a.zxy * b.yzx
            return i - j
        }
        cross_explicit :: proc(a, b: Vector3) -> Vector3 {
            i := swizzle(a, 1, 2, 0) * swizzle(b, 2, 0, 1)
            j := swizzle(a, 2, 0, 1) * swizzle(b, 1, 2, 0)
            return i - j
        }
        blah :: proc(a: Vector3) -> f32 {
            return a.x + a.y + a.z
        x := cross(a, b)
        fmt.println(x)
        fmt.println(blah(x))
}
```

4.2 Vstupní bod programu

Obvykle vstupním bodem programu ve vyšším programovacím jazyce je nějaká tzv. main funckce. Taková funkce muže mit za ukol předání vstupních argumentu programu a oddělení globalního scope.

Samotný koncept mi přijde obskurdním:

- Prvně, main funkce zvyšuje indencí kodu a zesložituje strukturu programu bez možnosti se tomu vyhnout. Když, například, uživatel bude chtít začít v lokalním scope, protože je to to, co se mu libí na main funkci, tak to muže udělat přímo za pomocí odpovidajicího syntaktického kostruktu. Dokonce, když to uděla, tak jasně da čtenáří znat svou myšlenku.
- A za druhý, ruší chápaní pořadí vykonání instrukcí. Instrukce se totíž běžne
 mohou objevít i v gloablním scope. Ovšem, protože z main funkce nelze nijak
 skočít do globalního scope, ale stale se jedna o misto, kde by měl program začít
 své konání, tak není jasné jak, a jestli vubec, se provedou globalní instrukce.

Jako vstupní bod programu jsem tedy zvolil počatek souboru, obdobně jako v Pythonu, nebo, když mám vybírát z C-like jazyku, jak v HolyC.

4.3 Alokace

Dynamickou alokaci bych nevnímal jako funkcí, operator, nebo výraz, ale jako samostatný celek, ktery by sloužíl alternativou při přiřazení. Tedy, že by přířazení buď bylo alokaci, nebo výrezem. Smyslem je vždy zaručit, že dynamicky alocovaná paměť bude vždy přířazena proměnné.

Syntaxi jsem zvolil nasledující

```
int^ ptr = alloc 8; // alokuje 8 bytu
int^ ptr = alloc int[8]; // alokuje 8 * sizeof int
```

Při alokaci při deklaraci lze vynachát datový typ na pravé straně, jestli má byt schodný s tím na levé. Formalně je to možné, protože alloc je alternativní rvalue, oprotí výrazu new v C++ či D, ktreý by se měl řidít pravidly vyrazu.

Nasledující řadky by tedy vyjadřovali to same.

```
int^ ptr = alloc int[8];
int^ ptr = alloc [8];
```

Navíc bych umožníl přimou inicializací za pomoci symbolu :, ktery se využívá v jazyce jako počatek přikazu. Nasledující kod inicalizuje alokuje velikost odpovidající int a a bude inicilizována na 1.

```
int^ ptr = alloc : 1;
```

4.4 Komentáře

V C, nebo napřiklad i v C++ a D nelze vnořovát blokové komentáře /**/. Není to vyznáčný nedostatek, ale stalé nepřijemny, pokud se komentuje něco, co už obsahuje komentář. Navíc se je to nekonzistentní s řadkovými komentáří, ktere se mohou vnořovát.

Volil bych nasledující syntaxi.

4.5 Pole

Jedna se o nejzákladnější a nejužitečnější datovou strukturu vyskytujicí se v programovani. V C se ovšem pole daji používat jen ve statických případech, kdy velikost lze stanovit ještě při kompilaci. Ovšem, i v připadech, kde je to dostačující, tak při využíti pole jako argumentu funkce se funkce buď musi definovat pro konkretni velikost pole, anebo obecně pro ukazatel.

První případ je použitelný jen zřídka, jelikož nepřináší abstrakci, která se intuitivně pojí s vybránym datovým typem. Muselá by se vytvořít pro různé velikosti poli samostatná funkce. To se muže řeší předaním pole přes pointer a buď ukončením pole nějakým specifickým symbolem, nebo předáním doplňujícího parametru délky.

V takovém to připadě se však ztraci jaka koliv vyhoda vybraného datového typu, a vlastně i konceptualní smysl onoho. Kod je ve vysledku méně explicitní, a navíc více nadolný na chyby, jelikož compile-time informaci, ktera se poji jen k jedne proměnné, se rozvádí do dvou run-time.

Stanovíl bych tedy některe zakladní požadavky pro pole. Mělo by byt využitelné ve funkcich bez ztraty identity a při tom byt implicitním ukazatelem na počatek svyćh dat pří přiřazeni do pointeru. Navíc, rozšířít typ i na dynamické pole a dynamické pole variablní délky.

4.5.1 Délka pole

K získaní delky pole jsem zavedl nasledující syntaxi.

```
int[8] arr;
arr.length; // vrati delku pole, tedy 8
```

Při předani pole do funce by se tedy předaval ukazatel na data a jako skryty parametr velikost pole. Pro připady, kdy neni potřeba předavat velikost, by se mohl použit pointer a implicitní přetypovaní.

4.5.2 Typy poli

Po mimo klasického rozdělení poli na statická a dynamická, bych chtěl umožnít jejich dělení v zavislostí na variabilnosti délky. To by umožnílo vytvařet funkcím vice specifická rozhraní pro práci s poli. Napřiklad by int[const] by vyznačovalo konstantní délku a funkce, která by neměla potřeby měnit velikost vstupního pole by pak mohlá přijmout jak statické, tak i dynamické pole.

Navíc bych chtěl integrovat array list do jazyka v ramci poli, jelikož je to často využivaná struktura. Array list bych viděl jako automaticky rozšířovatelné pole tak, aby vždy šlo zapsat na zvolený index.

Pole konstantní compile-time znamé délky

Jedna se o pole analogické tomu, co je v C. Tedy

```
int[8] arr;
```

by vytvořilo pole o delce 8. Spočtená délka by se vždy dosazovala compile-time, realná proměnna by se pro jeji uchovaní negenerovala.

Pole konstantní run-time znamé délky

Jedna se o analogii alokace konstantního ukazatele v C, ktery by byl využivan jako pole.

```
int* const arr = malloc(sizeof(int) * 8);
Tedy
  int[const] arr = alloc int[8];
```

by alokovalo pole o delce 8 na heapu a vygenerovalo by přislušnou proměnnou pro uložení délky někde v pamětí programu. Pole by, samozřejmě, nešlo realokovat, jelikož delka pole je obecně run-time znama, a tedy není možnosti ověřit při kompilaci jeji neměnnost.

Pole variabilní run-time znamé délky

Analogie využití ukazatele jako pole v C.

```
int* arr = malloc(sizeof(int) * 8);
Tedy
int[dynamic] arr = alloc int[8];
```

by alokovalo pole o delce 8 na heapu a vygenerovalo by přislušnou proměnnou pro uložení délky někde v pamětí programu. Pole by šlo realokovat.

Array List

```
Šel by vytvořít nasledovně
```

```
int[] arr;
```

nebo se specifickou počateční delkou, v tomto připadě 8.

```
int[] arr = alloc int[8];
```

Volba kvalifikatoru

Lze take vnímat dynamické pole za výchozí, a ne array-list. Pak by se využíl kvalifikator při inicilaizací array-listu, pole variabilní run-time znamé délky by se inicializovalo bez kvalifikatoru. Takovým kvalifikatorem by mohl byt třeba auton od slova autonomus.

Tato varianta se protířečí s zakladní představou o jazyce. Na druhou stranu se ale zbavuje implicitní alokace, protože ona varinta se již musí konkretně zvolit.

Přiklady jiných jazyku

C++ ponecháva vše jak v C. Řeší vše za pomoci konteineru definovaných v std knihovně. Nema však analog dynamického pole, ale nabizí std::span, který muže sloužít jako interface pro souvislý kontejner, nemuže však sloužit přímo jako kontejner pro data.

```
std::array<int, 8> arr;
std::vector<> arr;
```

D obohacuje jak statické, tak i dynamické pole o délku.

```
int[8] arr;
int[] arr = new int[8];
// v obou připadech delka dostupná jako
arr.length;
```

Odin ma k dispozici statická pole, slicy, ktere se využivají obdobně jako std::span, ale umožňují alokaci, a tzv dynamicka pole, ktere je analogem array listu pro jehož deklaraci se využívá kvalifikatoru na mistě délky. Všechny maji dostupnou funkcí len vracejicí jejich delku a dynamické pole muže využit funkce cap k získaní realné alokované délky.

```
arr: [5] int // static
arr: make([]int, 8) // slice
arr: [dynamic]int
len(arr);
cap(arr);
```

4.5.3 Práce s polem

Protože cílem je vytknout identitu pole oprotí ukazateli, tak bych zdurazníl rozdíl mezí nimi i z pohledu prace s daty. Pole je na rozdíl od ukazatele kus pamětí obsahujicí stejně elementy za sebou. Tedy bych pole vnímal jako proměnnou definujicí stejné prvky. Akce provaděne se samotnou proměnnou jako takovou (bez indexace), by se tykalí všech prvku v poli.

I když C formálně rozlišuje mezi ukazatelem a polem, v praxi často dochází k nejasnostem ohledně jejich identity. Napřiklad při nasledné deklaraci pole

```
int arr[8];
```

se vytvoří kontejner pro osum proměnných arr[0] až arr[7] o datovém typu int, který se specifikuje jen jednou. Použíje-li se kvalisifikator, tak se taky aplikuje na všechny prvky.

```
const int arr[8];
```

Aritmetické operace však nejsou aplikované na všechny prvky, ale chovají se k proměnné jako k ukazateli.

```
int* ptr = arr + 1;
```

V dusledku dvojakosti nasledující přířazení není dovoleno

```
int arr1[8];
int arr2[8];
arr1 = arr2;
```

jelikož pak není jasny zda se jedna o přiřazení všech prvku arr2 do arr1, nebo přepsaní ukazatele arr1 na ukazatel arr2. Což není z přečtení kodu zjevné, jelikož standardně se využivá kvalifisikatoru const k zakazaní přiřazení do proměnné.

Navíc, syntaxe řešící onen problem již v jazyce je, což přinaší jetě špetku zmatku.

```
const int* const ptr;
```

Jasné rozdělení mezi ukazatelem a polem na úrovni datových typů umožňuje eliminovat podobné nejednoznačnosti. Stanovil bych, že kvalifikatory jsou vždy vztažené ke všem proměnným v poli, že přiřazení pole do pole je definováno jako přiřazení jednotlivých prvku poli, že libovolné operace jsou vztaženy vždy na všechny prvky pole. Vyjimkou by bylo přířazení pole do ukazatele, kde se jedna o přetypování, a operace zřetězení (viz []), protože to postradá z definice smysl.

Tedy, například by pak bylo možné inicializovat všechny prvky pole na 0 nasledně.

```
int[8] arr1 = 0;
```

Nebo sečíst dva pole

```
int[3] arr1 = [ 1, 2, 3 ];
int[3] arr2 = arr1 + arr1; // [ 2, 4, 6]
```

a podobně.

4.6 Řetězce

V C řetězcové literály jsou pouze hezčí variantou zapsaní pole konstantních znaků. Ve své podstatě, i když je to primitivní, tak zcela postačující. Problemem je zde 'absence' identity pole jako typu, jak již bylo zmiňěno viz[]. Tedy vlastně se s každym řetězcem pracuje jako s ukazatelem.

Jelikož já definují pole jinak, tak lze rozvinout možnosti pole, aby umožňovali ve vysledku lehčí praci i s řetězci. Samotný datový typ pro řetězec existovat nebude, ale bude jen vestavěná podpora řetězcových literalu, které se při kompilaci rozloží na pole.

4.6.1 UTF-8

Bylo by vhodné rozšířít podporu literalu z ASCII na jiné kodovaní, které by umožnílo jednoduchou manipulaci se složitějšímí symboly. Jako takové kodovaní bych volil UTF-8, protože je kompatibilní s ASCII a blokem je byte, tedy neni zavísle na edianech a je velmi rozšířene.

Protože symboly v UTF-8 jsou variablní délky, víděl bych jako nejlepší možnost compile-time vyhodnocení nevětší delky potřebné pro uložení jednoho symbolu přislušného literalu a naslednou konverzi na pole integralních hodnot o patřičné velikosti, kde každy element bude samostatnym symbolem zakodovaným v UTF-8.

```
int16 str = "čau";
str[0]; \\ 'č'
str[1]; \\ 'a'
str[1]; \\ 'u'
```

To umožní pracovát se symboly samostatně, využívát všechny vyhody pole a mit pro ASCII text stejně velké pole jako v C. Tedy, napřiklad, leva strana muže definovat libovolnou velikost k uložení symbolu:

```
int32 str = "čau";
```

Aby bylo možné pracovat s řetězcovými literály jako s prostým kusem paměti, přidal bych možnost definovat tzv. surový (raw) řetězcový literál následujícím způsobem:

```
int^ str = "Hello"R;
```

Přiklady jiných jazyku

V jazyce D jsou řetězcové literály standardně ve formátu UTF-8 jako neměnné (immutable) pole znaků, ale pomocí postfixu u řetězcového literálu je lze převést na wchar (UTF-16) nebo dchar (UTF-32).

```
"hello"w;
r"ab\n" // Wysiwyg ("what you see is what you get") quoted strings can be d
```

V Odinu jsou řetězce také ve formátu UTF-8. Navíc obsahuje koncept tzv. rune, který umožňuje pracovat s jednotlivými symboly v řetězcích, kde rune reprezentuje Unicode kódový bod. Dále nabízí speciální datový typ cstring, který slouží k reprezentaci řetězců ukončených nulovým znakem kompatibilních s jazykem C.

```
str := "čau"
for r in str { fmt.print(r, '.') }
// vypiše "č .a .u ."
```

V Zig jsou řetězcové literály ve skutečnosti pouze ukončené nulou bajtová pole, která lze zapsat v kodu pomoci UTF-8 symbolu. Další rozšíření prace je dostupné prostřednictím standardní knihovnu.

```
const arr = "čau";
print("{d}\n", .{arr[0]}); // první byte 'č': 196
print("{d}\n", .{arr[2]}); // byte reprezentující a: 97
```

4.6.2 Operace

Jako jediné konvenční operace nad řetězcy, ktere by se měly integrovat do syntaxe, bych viděl zřetězení a vyběr podřetězce. Ostatní operace by už měly byt obsažené v standardní knihovně.

Zřetězení

Níc nového bych nevymyšlel, a použil operator .. jako v Lua.

```
u8[] str1 = "Hello";
u8[] str1 = "World";
u8[] str3 = str1 .. "__" .. str2;
```

Jelikož delká libovolného pole je získatelná, lze to zobecnít na jaky koliv typ pole. Je však duležité, aby implementace neobsahovalá žadnou alokaci pamětí, bylo by to zavadějicí. Tedy připadné vysledné pole by se muselo samostatně standartně alokovat prostředky jazyka.

Pro dynamické pole by to mohlo vypadadat nasledovně

```
u8[const] str3 = alloc [] : str1 .. "" .. str2;
```

Vyběr podřetězce

S podřetězce nebo výřezy polí se lze setkat v různých jazycích v ruzných podobách. Obvykle se jedná o reprezentaci libovolné souvislé části pole, která sama o sobě neobsahuje data, ale odkazuje na původní pole. Tedy v C by se slice dal definovat třeba nasledujicím zpusobem

```
struct Slice {
    int* dataPtr;
    int len;
};
```

kde dataPtr by ukazoval na nějaký element v puvodním poli, a 1en by specifikovalo délku. Odin a Zig napřiklad implementují vyřez (slice) pravě jako pointer na data a delku.

Odin, Zig a D napřiklad vnímají vyřezy jako datové typy a napřiklad je využivají jako nějaky interface pro dynamická pole.

Já bych nevnímal vyřez jako samostatný datový typ, ale spiš jako operací nad polem. Vyřezy by tedy byli datového typu pole, protože ve své podstatě je to to same. . . .

4.7 Jmenný prostor

Jedná se o jednoduchý, ale zručný nástroj pro organizací kodu. Umožňuje zhlukovat proměnné pod jedním společným názvem, který je rozlišitelný překladačem. Na rozdíl od použití identifikujících prefixů nebo postfixů v názvech je z hlediska nástrojů pracujících s kódem (např. LSP) strukturním celkem.

Umožňuje také při kompilaci hromadně pracovat s vnitřně definovanými proměnnými, čehož se dá efektivně využívat i pro import a export částí kódů. Například v Pythonu:

```
import foo;
from foo import x;
```

To, mimo jiné, také umožňuje řešit kolize názvů při importování knihoven (pokud nejste C++). Pokud by se jmenné prostory pouze importovaly, tak by si stále nesli svůj předem definovany název a s tím i možnst kolizi. Proto je vhodné napřiklad umožnít pojmenovování jmenných prostoru ze strany importujicího. Opět, napřiklad jak v Pythonu:

```
import foo as boo;
```

Jmenné prostory bych viděl jednoduše jako pojmenovaný scope.

```
namespace Foo {
    int x;
}
```

Pro přístup k prvkum bych využíl syntaxe z C++.

```
Foo::x;
```

4.8 Systém importu

Hlavičkové soubory a s nimi spojený systém importu bych kvalificiroval jako nejhorší část C. Jejich hlavní nevyhodou je duplicita definic. Slouží však k dobrému úmyslů – izolaci implementace a definici rozhraní. Cílem tedy bude zachovát tuto myšlenku, ale vyhnout se jak preprocesoru, tak i duplicitě.

Základním celkem bude soubor, jelikož jeto to co se ve vysledku předá překladači. Překladač dostane jen jeden vstupní soubor, ktery nasledně již za pomoci prostředku jazyka umožňí načíst další soubory. Všechny importy však budou probíhat v rámci AST, každý soubor by tedy měl být samostatně parsovatelným celkem.

Intitivně se nabizí možnost přímého importu souboru nasledující syntaxi:

```
import filename;
```

Ověšem, této možností bych se vzdal. Přijde mi, že by jen vybízela k "nesprávnému" přistupu při importování viz [Jmenné prostory], a nepřenašelo nic, co by nešlo řešit jinak.

Zavedl jsem tedy variantu, která by vždy zabalovalá soubor ze strany uživatele importu.

```
import filename as namespace Foo;
```

To by vytvořílo jmenný prostor Foo a překopirovalo kořen rozparsovaného souboru filename do něj.

Syntakticky se specialně specifikuje namespace, protože jsem se rozhodl onen konstrukt využít k implementaci jiných zpusobu zabalení souboru. Napřiklad:

```
import filename as scope;
import filename as fcn foo;
```

Dále tento konstrukt lze rozšířít a zavest import jen vybraných symbolu ze souboru.

```
import from filename foo, boo as namespace Foo;
```

V zásadě tohle umožní robustní import, a více prostředků není potřeba. Zbývá zohlednít viditelnost jednotlivých identifikátorů.

Lze buď vycházet z toho, že vše je viditelne, a omezuje se viditelnost, nebo naopak, vše je nepřístupné, a rozšiřuje se přístup. Druhy přístup je víc prakticky, ale ztrácí na explicitnosti, protože, když importujeme soubor, tak intuitivně očekáváme, že se nám tam naimportuje všechno (nebo alespoň něco), než nic.

Podstatnější je však otázka viditelnosti vnořených importu. Tedy, importuje-li soubor identifikátory z jiného souboru, budou-li viditelné také. Zřejmé je, že pokud jsou přistupné při importu, tak by měly být přístupně i pro další importy, jelikož jsou na stejné úrovní jako kód souboru, a nekladlá se žádná omezení.

Tedy, navrhoval bych umožnit omezit viditelnost importu, než omezovat viditelnost samostatných identifikátorů. Pak by byla decentní explicitní možnost omezení viditelnosti symbolu, aniž by se to muselo řešit poprvkově, a navíc by stale byla možnost vytvoření připadného rozhraní z dostupných symbolu, ktere by se umisitili do jednoho souboru a zbyle by se importovali lokalně.

K označení lokalních importu bych použíl slovo local

```
import filename as local namespace Foo
```

Samotná klasifikace proměnných dle viditelnosti by se mohlá kdyžtak řešít za pomoci direktiv. Napřiklad:

```
#private
fcn foo();
```

4.9 Přetěžování funkc

I když se jedna o implicitní konstrukt, který skryva od čtenáře pravou identitu volané funkce, tak přinaši, z mého hlediska, jednu zasadní věc, zjednošuená jmena funkcí.

Tedy, zamisto třeba vepisovani datového typu do jmena funkce, k rozlíšení funkce, lze jen uvest jeji činnost.

To zjednodušuje vnimani samotného programu, jelikož při praci s vlastnimi datovymi typy, ktere definuji složité objekty, jmena funkci budou už znatelnou zatíží, oproti např. maxi, lmaxf, lmaxu, kde lze přibližně vydedukovat typ očekavane proměnné.

Navíc jmena samotných funkci s použitím identifikujicích postfixu/prefixu, nebudou samostatnými celky z hlediska nastroju pracujicích s kodem, tedy v zakladu samotným kompilatorem a např LSP. I když by to šlo řešit za pomoci jmenných prostorů, tak to jen zhoršuje jmennou stopu.

Samotná abstrakce nad konkrétní volanou funkcí není pro čtenáře nijak zavádějící. NNebo spíše, je zavádějící stejně jako smyčka for, která místo abstraktní intrukce for provádí skoky a sem a tam. Smysl čtenář získáva ze samotného názvu funkce a vstupních proměnných, přičemž samotná konkretní funkcí je pro něho jako černoá skříňka. I když ona funkce dostava int, tak nelze vědět, jestli ten int neni hned první instrukci přetypovan na float. Tedy jediné co to ovlivní je rychlost nalezení spravné funkce při potřebě se podivát na jeji kod, což, bez užití LSP, bude zřejmě delší. Nicmeně, neřekl bych, že se jedná o něco zavažného.

Z mého hlediska, je lepší ho mít, než nemit. Zbyva tedy rozhodnout, zda povolit implicitni přetěžování, jestli muže platít

```
int foo(int x);
foo(1.0);
```

nebo pro jiny datový typ musi byt explicitní přetypování:

```
foo((int)1.0);
```

Explicitním uvedením datového typu lze identifikovát volanou funkci. Ovšem, existujeli potřebná varianta se dá dozvědět při psání kodu jen z LSP. V takovém to připadě je explicitní přetypování z hlediska informace nadbytečné (v porovnání s implicitním přetěžováním). Alternativně až po kompilací.

Tedy, faktické využití explicitního přetěžování je obdobné assertu, kdy je vyžadována konkrétní varianta funkce, a při její absenci se očekává chyba při kompilaci. Nicméně, přetypování by se muselo specifikovat u každého volání přetížené funkce, což se pře s hlavním cílem – zjednodušení jmeňné stopy. A to nemluvě o tom, že vlastně tatež informace existuje dvakrát: jednou při definici a podruhé při volání.

Bylo by tedy vhodné mit implicitní přetěžování, ale s opci v jistých připadech vyžadat přesnou kontrolu datových typu při vyhledavaní funkce. Zvolil jsem nasledujicí symboliku:

```
foo!();
```

Využití prapodivného symbolu v tomto připadě není zavadějicí, jelikož očekavané intuitivní chovaní vyrazu se nemění. Jedna se stale o function call, ktery nijak nemění

vysledky volaní ani jeho vstupy, z hlediska čtenaře je prakticky irelavantní.

4.9.1 Přistup jiných jazyku

Odin obsahuje pouze explicitní přetěžování, jelikož jazyk umožňuje definovat vnořené funkce ve funkcích, a tudíž rozlišení konkretní funkce, ktera se ma zavolat, není trivialní.

Zig nema přetěžování funkcí, ale podobného chování lze docilit při kompilaci za pomoci tzv. duck typing a metaprogramování.

```
fn add(comptime T: type, a: T, b: T) T {
    return a + b;
}

const result = add(i32, 1, 2);
const resultFloat = add(f32, 1.0, 2.0);
```

D a C++ maji implicitní přetěžování funkcí.

4.10 Spravá chyb

Uvažuje-li se C, tak jazyk nenabizí přímý způsob správy chyb. Chyby lze řešit například návratovou hodnotou, specifickým stavem očekávané výstupní proměnné předané přes ukazatel (často NULL), speciální funkcí vracející poslední chybu apod. V zásadě je to na programátorovi, aby vytvořil nějaky system pro správu chyb, a jestli vubec.

Při práci s libovolným kodem je pak nutne číst komentaře k funkcím, externí dokumentaci apod. To opěť vede na problem, kdy důležita informace není současti strukturních elementu kodu, ke kterým by měly různé nastroje přístup. Navíc to postrada jednotnost, jelikož různé knihovny mohu řešit správu chyb vždy odlišně. Ve vysledném programu se tak bude muset řešít zbytečný problem – jak s tím naložit.

To vše mně ve vysledku vede k myšlence o přídaní standartního systemu pro spravu chyb.

Z metod řešení jiných programovacich jazyku standartizovánou spravu chyb lze v zasadě vyčlenít dva přistupy.

Návratová hodnota Chyba je vracena jako navratova proměnná nebo jeji součast. Obvykle je to spojene s možnosti navratu několika proměnných, kde se vyděluje jedno, např. poslední misto, pro připadnou chybu (Odin), nebo je přímo specialní doplňujicí navratova hodnota vydělena jen pro chybu (Go). Take se třeba muže vracet struktura obsahujici jak připadnou chybu, tak i navratovou hodnotu (Rust).

Tenhle přístup je přímočarý a explicitní a dava svobodu programatorovi jak a kde s chybou naložit. Zpracování chyby je pak přímou součástí toku programu.

Tedy chybovy stav je prakticky jen další stav programu.

Try-Catch Využiva se system tzv. vyjímek, kde připadne chybové místo je zabalene do try bloku, a připadna chyby odchycena do catch bloku. To umožňuje napřiklad nezatěžovát kod spravou chyb a psat ho v try bloku tak, jako kdyby žadná chyba nastat nemohla. Odchycené chybá se nasledně zohlední v catch bloku.

"S try-catch se většinou pojí i tzv. throw mechanismus, který umožňuje označit případné chyby, jež může kód nějaké funkce vyvolat, a propagovat jejich ošetření do bloku, jež onu funkci volal.

4.10.1 Definice požadavků

Neprve bych si definoval požadavku chybového systemu:

- Jednotný datovy typ.
- Chyby by bylo možne seskupovát do skupin, ktere by se mohly kompozičně skladat. Napřiklad existujou-li samostatné skupiny chyb pro čtení a zaspis do souboru, tak by mělo byt možné spojit do společné skupiny.
- Definice funkce by měla specifikovat chyby, které mohou byt při jejim volaní vracene.
- Umožnit jednoduchou propagací chyby zasobníkem funkcí dal. Tedy zjednodušít obdobny často se vyskytujicí konstrukt:

```
err = foo(); if err != null : return err;
```

4.10.2 Implementace

Protože nahlížet na chybu jako jen na další stav programu, i když, řekněme, speciální, je z mého hlediska přirozenější a implicitní přístup neobsahujicí skryty tok řízení, tak jsem zvolil cestu návratové proměnné.

Jelikož funkce mají k dispozicí jen jednu navratovou proměnnou, chyba se bude vracet samostatným kanálem. Nicmeně, nechtěl bych vnímat chybu jako přímo navratovou hodnotu určenou jen pro chybu, jak je tomu např. v Go. Protože pak se pro každé volaní funcke musí řešít dvě vystupní proměnné. To ve vysledku povede k vytvoření buď implicitních pravidel, nebo k rozvláčné syntaxe.

K bližší předstě uvedu nasledující příklad v Go. Symbol := vyjadřuje, obdobně jako v Pascalu, deklaraci s inicializací.

```
func foo() (int, error) {
    return 42, nil;
}

val1, err := foo();
if err != nil { . . . }
```

```
val2, err := foo();
if err != nil { ... }
```

Intuitivně zde neni zcela zřejmé, co se ma dít. Prvně se provádí definice val1 a err, načež se ve stejném rozsahu platnosti provádí definice val2 a opět err.

Samozřejmě, je to zohledněné pravidly jazyka, kod je kompilovatelny a nová definice err se neprovede. Ovšem, dochazí ke sporu syntaxe a semantiky, kde ze syntaktického hlediska se err chova jen jako druhá navratova hodnota, ale ze semantického se implicitně provadí 'vyjimky' v pravidléch, jen protože se jedna o chybovou hodnotu.

Navíc se to kompilkuje přidaním kvalifkatoru. Bude-li se napřiklad chtit označit val1 jako const ale ne err, nebo naopak, bude-li se chtít mit jedno embed a druhý const. To lze řešit na ukor upovidané syntaxe, bude-li se chtit zachovát explicitnost, nebo přidaním implicitních pravidel. A tedy obdobné řešení mi nevyhovuje.

K navratu chyby bych využil pravé strany příkazu. To umožní syntaktický oddělít samotný přikaz a ošetření chyby. Navíc to muže do budoucna umožnít odchycení chyby nejen z jednoho volání funkce, ale i z libovolného vyrazu obsahujícího i několikero volaní funkcí.

Volil jsem nasledující syntaxi

```
error err;
int x = foo() catch err;
```

kde by error reprezentoval datový typ chyby a připadná chyba by se v tomot připadě uložila do proměnné err.

Zde bych stanovíl, že nechci zbytečně obohacovát datový typ chyby o implicitní chování, nebo konstrukty pro tvorbu chyb. Chyba by byla vždy datového typu error a chovála by se vždy stejně.

Kuriozně se lze v takovém to připadě dopustít jedné vyjimky – pominutí samotné defince chyby před odchycením – jelikož je redundantní, místo odchytu totíž muže jen pracovát s datovým typem error.

```
int x = foo() catch err;
```

Protože by to však bylo jak zavadějicí, tak bych chybu onu chybu definoval jen lokalně pro nasledující rozsah platnosti, kde by mohlo byt umistěné jeji spracovaní. Samotný rozsah platnosti by se nelišil chováním od klasickych.

```
error err;
int x = foo() catch err; // odchycuje globalně
x = foo() catch err {
      // odchycená chyba použitelna jen zde
      print(err);
}
print(err) // chyba s prvního volání
```

Množiny chyb

Samotna chyba by měla byt jednoduše identifikovatelná přes své jmeno, aby ji bylo možné použivát pro určení stavu. Napřiklad:

```
if err == ErrName : foo();
```

Chyby by měly byt shlukovane do uživatelem definovaných skupin, ktere by pak sloužili pro určení chybového rozhraní funkcí. Skupiny by měly byt shlukovatelné, jelikož funkce by měla mit možnost navracet i chyby uživaných funkci, ktere mohou byt definované samostatně, aniž by se pro ní redundantě definovaly nové chyby.

Tedy, řekněme, že budeme moct definovat jakési množiny chyb, a jen je. Použijeme nasledující syntaxi.

```
error ErrorSetA {
    ErrorA;
    ErrorB;
};
error ErrorSetB {
    ErrorSetA;
    ErrorB;
};
```

Pak ErrorSetA je množina obsahující prazdné množiny ErrorA a ErrorB a ErrorSetB obsahuje množinu ErrorSetA a prazdnou množinu ErrorB. Libovolná s těchto množin by měla byt identifikovatelná svým jmenem a byt přiřazena do datového typu error.

```
error err = ErrorSetB::ErrorB;
```

K definici chybového rozharní funkce se pak použije nasledující syntaxi.

```
fcn foo() using ErrorSetB -> int {...}
```

Funkce foo pak muže vracet chyby definovane v ErrorSetB.

Protože oné množiny maji smysl jen při definici samotných funkci a definice funkce ve funkci není umožněná, tak jejich definice uvnitř funkcí je zavadějicí, a tudíž zakazana. A tedy mužeme vnímát oné množiny jako nadstavbu nad namespace pro chyby, a tedy k jejich diferenci použivat stejný symbol ::, jak již bylo naznačeno viz[...].

Toto řešení je jednoduché a relativně všestranné. Umožnuje napřiklad rozvít některou prazdnou množinu na plnohodnotnou, aniž by se rozbil kod využivající onu množinu. Ovšem, ma jeden zakladní nedostatek – vracíme pouze stav. Tedy nemužeme vratít inforamci o chybě. Teoreticky je to řešitelné přidaním nových stavu, ovšem to zdaleka není prakticke.

Prakticky to omezuje jen při logovaní chyby, protože jinak vždy popisujeme stav programu, ktery je nezbytny z hlediska jeho činnosti. Tudíž přidani v takových to připadech chybového stavu je vlastně nezbytné (uvažuje-li se, že tento stav je vhodné vnímat jako chybovy, obecně to lze řešít normalní cestou).

Ve vysledku je to jen něco, co slouží jako doplnění systemu. Něco, co je využiváno přímo při zpracovaní samotné chyby, a tedy neruší samotnou standartizaci, která se kladla za cil, protože popis samotné chyby už není obecně standartiyovatelný, a tak čí onak se jedna o konkretní zaležitost.

Pokud by se navrhnutý model zobecnil definici chyby za pomoci struktury nebo unie, tak vlastně dojde k rozporu se standartizaci. System se totíž zobecní natolik, že bude moct byt využívan i pro jiné věci, a mnohy zpusoby. A tudíž se vlastně postaveny problem nevyřeší, jen se přesuneme jinam.

Mohl bych povolit přiřazení chybam konkretních hodnot, což by mohl byt postačujicí kompromis. To umožní pak indexovat pole hodnotami chyb, což je ve vysledku velmí silný nastroj.

Navrat chyby

Možnost v chybovém stavu vratít i normalní hodnotu z funkce je zručna zaležitost. Muže posložít jako napřiklad doplňujicí informace o chybovém stavu. Navíc, je to dokonce nutná zaležitost, jelikož vnímame chybu jen jako další stav, a ne jako něco zvlaštního.

Volil bych nasledující intuitivní syntaxi:

```
return value, err;
```

Kde value představuje proměnnou s navratovou hodnotou, a err navratovou chybu.

Pak navrat jen hodnoty je nezměnný, ale otázkou je navrat jen chyby. Lze k tomu přistoupit tak, že vlastně takovy to připad existovat nebude, tedy vždy spolu s chybou se vratit i hodnota. To take zaruči, že proměnna, do ktere se zapiše navratova hodnota, nebudeme mit neurčenou hodnotu. I když je to skvělé chování, nelze ho použit. Ma-li byt jazyk nízkoúrovňový, musí take dat programatorovi i kontrolu. Nelze jen tak zbytečně vnucovat instrukci. Tedy, přidal bych symbol, např _ definujici přeskočení proměnné, a skončíl s nasledujícím kodem:

```
return _, err;
```

Implementace v jiných jazycích

4.11 Kontext

Koncept, ktery umožňující měnít chování kodu dle svých potřeba a tím i znovvyuživat kod pro konkretní potřeby. Ovšem, když je kontext explicitní, tedy je předaván jako parametr funkce. Pak je to jen na konkretní knihovně nabidne li vubec kontext a když ano, tak jaky.

Implicitní kontext, ktery integrován do jazyka pak umožňuje řešit onen problem. Obzvlášť je to výhodne v jazykach s manualní kontrolou paměti, kde za pomoci kontextu se dá řešit problem použití vlastních alkoatoru. Takovými jazyky jsou třeba Odin a Jai.

print, mem alloc, etc.

4.11.1 custom alloc

4.12 Compile-time exekuce

V ramci optimalizace kompilatory mohou provádět provadět vypočty některých výrázu pokud je dostatek informace. Tedy například:

```
int x = 5 + 3 * 9 - 2;
```

Výraz definující x se muže předpočitat a za běhu programu se nebude muset níc vypočitavat.

Ovšem, to vše je provaděno implicitně. Podstatnou možností je ale mit kontrolu nad compile-time exekucí ze stranky jazyka. Koncepce je zpravidla obsažená v nějaké formě v nizkourovňových jazycích, jako napřiklad C++, D, Odin, Zig, Rust, atd.

K deklaraci compile-time proměnné bych využil klasifikatoru embed od slova embeded (vestavený), protože slovo odraží smysl, a vzníka obdobně jako const. Navíc má stejnou delku, což by při nasledných deklaracích vypadalo dobře:

```
const int x;
embed int y;
```

Implementačně by proměnna neexistovala, ale vždy by se využivala jeji spočtená hodnota.

Takový to jednoduchý klasifikator pak umožní provadět velmí složíte compile-time vypočty. Protože ze své podstaty embed specifikuje, že proměnná má byt spočtená při kompilaci, fakticky tedy jaka koliv nebyla pravá strana výrazu, kompilator se ji pokusí vypočíst, a buď uspět, nebo ukončit kompilací s chybou.

what should happen at compile-time, does happen at compile-time.

Lze se tedy napřiklad pokusit vypočíst hodnotu libovolné funkce při kompilaci přičemž funkce se nemusí specialně předeklarovat jako compile-time jako v C++:

```
fcn add(i32 x, i32 y) -> i32 { .. }
embed int ans = add(4, 2);
```

Obdobně to funguje v D, kde se da využít enumeratoru k definici compile-time proměnné a spočist pravou stranu:

```
int add(int a, int b) { ... }
emnum ans = add(4, 2);
```

Nebo třeba v Zig parametry funkce comptime umožňuje parcialně comptime-runtime funkce.

```
fn add(a: u32, b: u32) u32 { .. }
const ans = comptime add(4, 2);
V C++
```

```
constexpr int add(int a, int b) { .. }
constexpr int ans = add(4, 2);
```

5 Implementace kompilatoru

K implementaci kompilatoru jsem použil jazyk C++ využivajíc standartu C++20. Jako cilovou a vyvojovou platformu jsem zvolil Windows, kde jsem využil Visual Studio předkladače (cl) a Visual Studio 2022 k ladění. Jako IL jsem vybrál jazk C, protože jsem s ním a s nastroji pro pro práci s ním dobře znám. Pro překlád generováného C kodu jsem zvolil Tiny C Compiler (TCC), a konkretně jeho knihovnu libtce, ktera umožňuje vestavenou kompilaci C kodu.

Jedná se o konzolovou aplikaci, která prácuje se soubory na disku. Tedy, zavislot na operačním systemu není tak velka a std knihovná z větší častí pokryla rozdily Windows a Unixu. Po mimo rozdílu v systemových funkcích, jako třeba získání cesty k spustítelnému souboru, která nejde získat skrz std::filesystem, se hlavně líší knihovný a cesty potřebné pro run-time libtcc. Protože se mi podařílo program uspěšně zkompilovat pod Ubuntu 22.04.5.LTS, port pro Unix by tedy měl byt jednoduše realizovatelný.

5.1 Strukturá

Strukturá aplikace je nasledujicí. Nejprve je zpracován uživatelský vstup ve formě argumentu z přikazové řádky. Ten je převeden do konfigurace modulu Compiler. Modul Compiler je reprezentován jmenným prostorem, a tedy je staticky. Modul provádí v zasadě čtyří věci postupně. Nejprve běži parser, který inicializuje a zaplní AST. Dále běži validator, ktery již provede semantickou kontrolu AST. Nasledně je kod přeložen instanci modulu Translator. V zavislotí na uživatelském vstupu vystup překladače muže byt převeden do binarní podoby a popřipadě hned spuštěn.

Cílem bylo dospět k robustné implementaci, ktera by dokazala vytvořit zakladnu pro dalnější, řekněme, idealní, implementaci kompilatoru, ktery by byl specificky pro danny jazyk. Tedy, hlavním ukolem bylo přijit s AST, které by se dalo využit jak pro překlad do libovolného IL, tak i které by bylo možné využít ve věstaveném interpreturu.

Zatím se za cíl nekladlo rychlost řešení, ale spíše předložit důkaz konceptu pro navržený jazyk.

5.2 Uživatelské rozhrání

Pro komunikaci s uživatelem se využívá argumentu přikazové řádky. Uživatel má v zakladu tři hlavní přikazy nasledující jménem vstupního souboru, na který maji byt aplikovane:

build Přikaz sestaví program do spustitelné podoby.

run Přikaz sestaví prográm do spustitelné podoby a bezprostředně ho spustí v terminalu.

translate Přikaz pouze přeloží do vybraného IL.

Nasledně mohou byt uvedené doplňující možností dostupné pro každy přikaz:

- -ol (Output Language) Vybere, ktery IL použít, prozatím jen C.
- -of (Output File) Jméno vystupního spustitelného souboru bez rozšíření.
- -od (Output Directory) Určí složku, do které se uloží vystupní přeložené IL soubory.
- -gd (Generate Debug information) Jestli se má vygenerovat debug informáce.
- -h (Help) Vypiše napovědu ohledně uživatelského rozhrání.
- -b (Batch/Bash) Říka překladačí, že je spouštěn ne přímo uživatelem, ale za pomocí skriptu.

Samotná implementace samotného rozhrání byla trivialní, pouze za pomoci for smyčky a funkce strcmp. Žádné hashování se neprovadělo. Jedinou zajimavou časti byla implementace přikazu run.

Přikaz run potřeboval umožnít spustít zkompilovaný program po kompilaci. Lze třeba použit std::system, ovšem, v takovém to připadě nelze ukončit překladač a dalé použivat stejný terminal pro komunikaci se spuštěným programeme. To mi nevyhovovalo.

Na POSIX systemech lze využít funkcí fork a exec z <unistd.h>, jejichž po sobě jdoucí volání nahradí běžicí process za zvolený. Windows však nenabizí obodbu funkce fork, k dispozicí má pouze funkcí CreateProcessA, která se dá využít k vytvoření processu s konkretním nastavením. Ovšem, nelze, nebo alespoň se mi nepodařilo, docilit obdobného chování jak u fork a exec. I když samotný process pro ukončení hlavního programu dale komunikuje s terminalem, samotný terminal se po ukončení puvodního processu vždy vypiše prompt.

Tedy, na Windows, pro docílení idelaního chování, kdy spuštěný program používá stejný terminal a na venek se to tváři jako stále jden program lze jen za použití třetího programu, ktery by sloužíl prostředníkem a nejprve spustil kompilator a nasledně, v zavislostí na vystupu onoho, zkompilovaný program. Takový to program jsem implementovál jako bat skript.

5.3 **AST**

Centerm programu je statické AST jehož uzel se reprezentuje za pomoci struktury SyntaxNode. Kořen stromu je statickým prvkem SyntaxNode. SyntaxNode obsahuje i další statické prvky, které odkazují na kontejnery s cachovanou informaci, ktera by byla dostupná přímo, aniž by se musel procházet strom. Jedná se napřiklad o odkazy na proměnné, definice, funkce atd. Samotná definice pak vypadá obdobně:

```
struct SyntaxNode {
    static Scope* root;
    ...
    NodeType type;
    Scope* scope;
    Location* loc;
    ...
};
```

Každy uzel teda ve své podstatě nese informaci o svém typu, rozsahu platností a lokaci ve zdrojovém kodě.

Každy konkretní uzel pak dědí SyntaxNode, obdobně třeba vypadá uzel reprezentující while smyčku:

```
struct WhileLoop : SyntaxNode {
    Scope* bodyScope;
    Variable* expression;

WhileLoop() : SyntaxNode(NT_WHILE_LOOP) {};
};
```

I přesto, že Syntax Node představuje uzel stromu, tak neslouži k vyjadření všech syntaktických prvku. Samostatnou reprezentaci maji výrazy. Je to dané tím, že vnítřně vyrazy představují vyjadření hodnoty proměnné. Tedy v AST je vždy vyraz zastoupen proměnnou.

Obecný výraz je definovan velmi jednoduše:

```
struct Expression {
    ExpressionType type;
};
```

Pak konkretní výraz vypadá například nasledovně:

```
struct OperatorExpression : Expression {
    OperatorEnum operType;
};

struct BinaryExpression : OperatorExpression {
    BinaryExpression() { type = EXT_BINARY; };

    Variable* operandA;
    Variable* operandB;
};
```

Vyjadření hodnoty proměnné je pak představeno nasledovně:

```
struct Operand : SyntaxNode {
    VariableDefinition* def;

    Value cvalue; // c as compiler
    Value ivalue; // i as interpreter

    std::vector<Value> istack;

    Expression* expression;
    ...
}
```

Jedná se o vyjadření obecného operandu výrazu, proměnná se pak jen definuje jako pojmenovaný operand. Hodnota je tedy buď vyjadřená odkazem na definici, přímo hodnotou, nebo výrazem. Samotná hodnota se využívá i pro určení datového typu operandu a vypada nasledovně:

```
struct Value {
    DataTypeEnum dtypeEnum;
    int hasValue = 0;
    union {
        int32_t i32;
        int64_t i64;
        ...
        void* any;
};
```

Jak lze usoudit z atributů ivalue a istack v definici operandu, abstrakce hodnoty ve formě Value je použitá kvůli interpreteru, který s touto strukturou pracuje. Podrobnějc oné atributy budou představené v přislušné sekci [].

5.4 Parsing

Rozhodl jsem se nejit cestou generatoru jako je YACC, protože, ze zkušeností, bych stejně musel napsat veškerý kod pro sestavení stromu, neměl bych jednoduchý zpusob vypisování chyb libovolným zpusobem, měl bych omezeny přistup k buffrum souboru, neměl bych kontrolu nad paměti atd. Navíc bych nevyužíl vyhod při protytopování syntaxe, protože mam konktretní typ jazyka, který chcí implementovát, tedy bych jen mohl implementovát nutnou abstrakci pro zaměnu syntaktických celku.

Při implementaci parsru jsem se rozhodl nepoužit abstrakci ve tvaři lexru, jelikož mně jen zajimalo jaky to je, protože ve většíně publikaci se lexer používá a chtěl jsem si udělat nazor jinou implementaci.

5.4.1 Prace s paměti

Obecně jsem se rozhodl zatím neřešít dealokaci AST, protože překladač při chybě končí svojí činnost, a tedy bude rychlejší to přenechát OS. Ovšem, protože v budoucnu se nejspiš bude derivovát z překladače implementace LSP, tak by je nutné, aby veškera paměť, která je alokovaná a není součástí vysledného AST nebo jiných statických částí, byla dealokovana.

Každy soubor se vždy načte cely do pamětí a je obsažen v ní až do samotného ukončení programu. Je to nutné, protože v libovolný okamžík je nutné moct uživatelí vypsát nějaky relevantní kus kodu. Protože samotný nejpreve je sestaveno celé AST a až nasledně se provádí validace, tak se nemužou soubory postupně dealokovát.

Abych toho využíl, rozhodl jsem se ne alokovat paměť pro textové řetězce, ale používát vždy přislušného ukazatele do přislušného souboru.

5.4.2 Importy

Zvnějšku parser je jen jedná funkce přijimající na vstup jméno souboru, ktery oná vníma jako vstupní soubor programu. Vnítřně globalně parsing řeší dvě funkce, parseFile a processImport, které za pomoci structury ImportNode řeší parsíng všech dálších souboru a spojení jich do vysledného AST.

Každy soubor se parsuje do předem dodané instance Scope. Při parsování souboru se připadné importy zařazují postupně do přislušného uzlu importovácího stromu reprezentováného strukturou ImportNode. Importovácí strom slouží k zachování vztahu souboru a kontrole cirkulárních importu.

```
struct ImportNode {
    FileId* fileId;
    Scope* fileScope;
    ImportStatement* import;
    ImportNode* parent;
    std::vector<ImportNode*> children;
};
```

Aby se předešlo parsování znovu zpracování téhož souboru, každy rozparsovaný soubor se označíl unikatním id. Id bylo definovano nasledovně:

```
struct FileId {
    uint64_t size;
    std::filesystem::file_time_type time;
}
```

Jednalo se tedy o reprezentací souboru jeho velikosti a čásem vytvoření. Takový to přístup umožňoval rychle porovnovát ruzné soubory. Jinak by třeba šlo použít absolutní cesty k souboru, ovšem to mi přišlo nešikovné, protože obecně cesta muže byt všelijak dlouhá. Každy soubor byl pak ukladán do mapy a před parsingem se ověřoválo, jestli již existuje nebo ne.

Algoritmitický by se pak funkce processImport dala popsát nasledovně:

```
processImport(parentNode) :
    for node in parentNode :
        fpath = getRealFilePath(node.fname)
        node.fid = genFileId
        file = find(parsedFiles, node.fid);
        if (file) :
            node.fscope = file.scope
        else :
            parseFile(fpath, node)
            insert(parsedFiles, node.fid, node.fscope)
        if not doesImportExistsInPath(parentNode, node) :
            error exit;
        insertToAST(node);
    for node in parentNode :
            processImport(node)
```

Je nutné podotknout, že importovat symboly dopředu Scope je relativně drahé, protože se prvky v každém array-listu budou muset posunout. V připadě třeba funkci nezaleží na pořadí, protože neosahují sam o sobě spustitelný kod a jejich definice nemusí předcházet použití. Tedy je lze prostě zařadít nakonec. V připadech, kdy to nejde, krom zřejmé změny kontejneru na třeba list, lze alespoň posunout prvky jen jednou za soubor udělav posun až po zpracování všech imporu.

5.4.3 Samotný parsing

Parser jsem implementoval procedruralně, kde každa funkce relativně odpovidala syntaktickému celku, ktery má za ukol rozparsovat. Každa taková funkce dostavá pointer na buffer s textem a pointer na Location, které definuje lokaci, tedy hladvně index, ktery slouží jako přimy index do bufferu a číslo řadku.

Ovšem prakticky to není tak hezké, protože rozhodnutí, kterou větvi gramatiky se vydat se rozhodují vždy individualně a využivajic napřímo bufferu textu. Kdežto v připadě lexru bych mohl využít tokenu a buď indexace pole, nebo switch-casu v každém připadě, což by bylo vic čítelné.

Kličová slová se vnítřně namapovála na integralní hodnoty, což vytvořílo abstrakcí mezí samotnymi celky, které reprezentují a slový jako takovýmí. Navíc to umožnílo použití stejných funkcí pro zpracování ruzných množín slov. Napřiklad direktiv kompilatora. Pro zpracování kličových slov byl v zasadě použít jeden velky switchcase, protože mám rad switch-case. V budoucnu, ovšem, by ho bylo dobré nahradit indexaci pole, kde každy index by ukazoval na samostatnou funkci.

Operatory se reprezentovaly jako uint32_t, což imezoválo délku operatoru na 4 symboly (po připadě by šlo rozšířít na 8 za použití uint64_t), ale umožnílo indexaci. Omezení na malý počet symbolu pro operator není faktický omezujicí, protože většínou operatory jsou reprezentovany matematickymi symbolami nebo kratkymi slovy. Vyhoda je však vyznačná. Look-up operatoru mohl byt proveden nasledovně:

```
OperatorEnum findBinaryOperator(uint32_t word) {
    switch (word) {
```

```
case operators[OP_ADDITION].word : return OP_ADDITION;
...
case operators[OP_SHIFT_LEFT].word : return OP_SHIFT_LEFT;
default : return OP_NONE;
}
```

5.5 Validace AST

Úkolem bylo jak provést semantickou kontrolu AST, tak i obohadit AST o potřebnou semantickou informaci. Ve vysledku by AST mělo byt bezchybné a plně odpovidat navrženým podminkam. Tedy, ukazatel vždy směřuje na platné místo v paměti, které lze jednoznačně identifikovat podle daných pravidel, jinak má hodnotu NULL; vždy je použita správná hodnota enumerátoru; všechny doplňující příznaky jsou správně nastaveny; atd. Další moduly pak již nemusí řešít validnost a mužou slepě duvěřovát AST.

K validací se využívalo cachovaných odkazu na konkretní typy uzlu. To bylo provaděno lokalně v ramci rozsáhu platností a globalně pro celé AST. Tedy se nemusel procházet cely strom, ale mohlo se přímo sekvenčně přistupovát k většíně duležitym prvkům.

Během validace se provaděly nasledující akce:

- propojení definic uživetlem definovaných datových typu s jejich konkretnimi užiti.
- vzajemné propojení chybových množín
- propojení chybových množín užitých ve funkcích s jejich definicemí
- validace definic uživatelských datových typu
- propjení proměnných s definicemi
- propojení a validace *qoto* příkazu
- validace, že každá funkce má globální platnost
- propojení volání funkcí s definicemi
- vypočet všech compile-time proměnných
- vypočet, nebo převedení na výraz, délek poli
- kontrola argumentu volaní funkcí
- kontrola return příkazu
- kontrola správností přířazení a alokaci
- kontrola inicializaci

- kontrola podmíněných výrazu a switch-casu
- kontrola obecných výrazu

Data-flow

Duležitou otázkou bylo řešení správného přířazení proměnných k definicícm. V zasadě definice se daji členit do dvou kategorii. V jednom připadě definice je dostupná pro proměnnou nachází-li se v rozsahu její platnosti. Ve druhém připadě navíc musí platít, že definice předchází proměnnou.

První připad se dá řešít jednodušě, stačí aby strukturá definujicí rozsáh platností vždy měla kontejner pro uložení odkazu na vyskytováné v ní definice. Vhodným kontejnerem je hash mapa, prtože ta zaroveň umožní zachovát identitu nazvu už při parsingu. Pak stačí v připadě každé proměnné rekurzivně procházet rozsahý platnosti směrem ke kořenu a prohledavát kontejner na přemět odpovidajicí definice. Pseudokodem by to šlo reprezentovát nasledovně.

```
findDefinition(var)
    scope = var.scope
    while(scope) :
        def = find(scope.defs, var.name)
        if (def) return def
        scope = scope.scope
    return null
```

Druhý připad už byl o něco složitější, jelikož zaleželo na pořádí. Zřejmou možností by bylo postupovat obdobně, ovšem k uložení dat využít array-list. Pak v každem rozsahu platnosti se zachová pořádí. Jak lze ale chápat sekvenční prohledavání kontejneru textových řetězcu není zrovná rychlé. Navíc, by obdobný kontejner musel obsahovát nejen definice, ale i uzly reprezentující rozsahy platností pro zachování informace o pořádí mezí přechody z ditěté do rodíče.

Pokud by se situace zjednodušila a omezilo se jen na jeden soubor, tak řešít by to šlo na urovní parseru. Opět by se použilo hash mapy a každá proměnná by se testovála jako v prvním připadě přímo při parsingu. V takovém to připadě by v mapach neexistovali ještě definice, které by byli definovane za proměnnou. Ovšem, protože obecně chci mit možnost manipulovat se stromem na urovní AST, tak nemužu zaručít, že se pořadí uzlu po parsingu jednoho konkretního souboru nezmění. Navíc importy samotné narušují standardní tok definic Foo::Boo

Rozhodl jsem se tedy postoupit jinak a zavest nový atribut v SyntaxNode, ktery by definovál pořádí definic a ostatních potřebných elementu v ramcí Scope a vybral jsem pro něj ne moc vhodný nazev parentIdx. Smyslem bylo přiřadít při parsingu každemu potřebnemu uzlu index z pohledu jeho rodíče a při validaci při vyběru kandidata z hash mapy rozhodnout se v zavislostí na pořadí indexu.

Zde lze viděť schematickou ukázku již realné funkce upravenou pro ilustrační cíle:

```
Variable* findDefinition(Scope* scope, Variable* const var) {
   int idx = var->parentIdx;
```

```
while (scope) {
    SyntaxNode* node = find(scope->defSearch, var);

if (node) {
    if (node->parentIdx < idx
        && node->type == NT_VARIABLE) {
        return node;
    }
}

idx = scope->parentIdx;
scope = scope->scope;
}

return NULL;
}
```

I když se to muže zdat zavadějicí, protože se při manipulací s AST se uzly budou muset posouvát, tak je zde pár vlastností, které je nutné si uvědomí:

- Indexy jsou vždy relativní vučí Scope, a tedy se posune jen dilčí čast.
- Indexovát se musí jen specifické typy uzly, nemusí se procházet tolík prvku.
- Indexovát lze i do zaporných hodnot, jelikož se jedná pouze o nastroj k rozhodnutí o pořádí.
- Indexy se mužou duplikovát.

Napřiklad, u funkcí a jmenných prostoru nezaleží na pořádí, každa funkce tedy muže vždy mit index 0. Při importu rozsahu platností nebo jménného prostoru se žádná již existující proměnná nemuže odazat na jejich vnitřní proměnné a není nutno nic měnit. Pokud se importem přidavá definice na začatek souboru, což je zcelá běžné, tak se lze podívát na index stavajícího prvního prvku a použít index menší. A podobně...

Tedy, pokud se importy omezí jen na počatek souboru, tak bych řekl, že lze vždy docilit O(1) aktualizace indexu.

Přetěžování funkci

Klasicky přiřazení volaní funkce ke správné definici se ničím neliší od přiřazení proměnné definice, postačí jen jmeno. V připadě přetěžování funkcí už roli hrají i datové typy a počet vstupních argumentu. V připadě implicitního přetěžování již nejde identifikovat funkci striktně na rovnosti datových typu, viz příklad:

```
int foo(int x, float y);
int foo(float x, float y);
foo(1, 2);
```

Jak lze vidět, datové typy argumentu volání funkce foo striktně nesedí ani jedné definici, ovšem intuitivní je, že by se měla přiřadít první definice. Bude tak i napřiklad

```
v připadě C++.
```

K určení nejvhodnější funkce jsem tedy použíl jakehosi score, ktere sestavovalo v zavislosti na potřebě přetypování a datových typech, které se přetypování učastnili. Score bylo definováno jako int viz:

```
struct FunctionScore {
    Function* fcn;
    int score;
};
std::vector<FunctionScore> fCandidates;
```

Což pro moje učely bylo dostačujicí. Hodnoty score jsem rozdělil do čtyř kadegorii, v zavislostí na kategorii se pak přičetla přislušná hodnota do skore. Kategorie a zaroveň i hodnoty byli vyjadřeny enumeratorem nasledovně:

```
enum Score {
    FOS_IMPLICIT_CAST,
    FOS_SAME_SUBTYPE_SIZE_DECREASE,
    FOS_SAME_SUBTYPE_NO_SIZE_DECREASE,
    FOS_EXACT_MATCH,
};
```

Kde nejvyše hodnocenou kategorii je připad přesné shody. Dale nasleduje připad přetypování do stejného podtypu (napřiklad i32 do i64) bez snižení přesnosti. Na což navazuje obobný připad akorat se snížením přesnosti (napřiklad i64 do i32). A nejmeně hodnocenymi jsou pak ostatní jiné implicitní přetypovaní.

Zde by šlo obohatit model o vice kategorii a rozlišovát zda se jedná o přechod od neznamenkového typz do znamenkového a naopak, nebo rozlišovát na kolik se zvětšíla nebo zmenšíla přesnost při přechodu z jednoho typu na druhy. Ovšem, takové to chování jsem prozatím shledal jako zavadějicí.

Tedy, pro každé volaní funkce se nejprvé v jeho rozsahu platností naleznou funkce se schodnymi jmény. One funkce se uloží do kontejneru fCandidates. Každa kandidatní funkce se projde a spočíta se jeji skore v zavislostí na volaní. Na konec se vybere funkce s největším skore. Chyba nastane pokud budou dvě a vice stejná maximalní score, nebo nezbude žadna funkce se scorem.

Vypočet datových typu a výrazu

Nejprve jsem chtěl provadět vypočty datových typu spolu s evaluaci výrazu v jedné funkci, ktera by se pokusila spočíst každy uzel vyrazu a při neuspěchu by jen vyjadřila datový typ. Při procházení výrazu jsem ovšem vždy byl ve stavu, kdy se mohlá očekavát neplatná hodnota, která měla byt zohledněna. Dospěl jsem tedy k tomu, že by bylo vhodnější ty funkce rozdělít i když mají fakticky stejnou logiku.

5.6 Interpret

Protože compile-time evaluace je zakladem jazyka a musí byt umožněno vyhodnocovát prakticky všechno, rozhodl jsem to řešít implementaci vestaveného interpreteru. Ukolem interpreta je možnost jak evaluace proměnných a funkcí, tak i libovolného operatora.

Jak bylo zminěno, interpreter využíva specialního atributu ivalue v Operand. Atribut se využiva pro ukladani mezivysleku interpreta po spočtení každého uzlu. Postupně se tak spočitá hodnotá finalního, vstupního, uzlu a hodnota se přepiše do cvalue. Ovšem, to nestačí, protože se také musí řešit evaluace funkcí.

Evaluace operatoru

Samotným jadrem jsou dilčí funkcí umožňujicí evaluaci konkretních operatoru. Funkce jsou zabalené do unie, ktera umožňuje sjednotit ruzné typy funkcí:

```
union OperatorFunction {
    void (*binary) (Value*, Value*);
    void (*unary) (Value*);
};
```

Funkce v poli jsou seřazene seřazené do skupin dle datových typu, kde každa skupina je seřazená dle operatoru. Pořadí určuje vždy přislušný enumerator. Obdobně třeba vypada funkce pro použití operatora, kde, lze vidět zpusob indexace pole operatorFunctions:

```
int applyOperator(OperatorEnum oper, Value* v1) {
    OperatorFunction fcn =
        operatorFunctions[v1->dtypeEnum*OPERATORS_COUNT+oper];
    fcn.unary(v1);
    return Err::OK;
}
```

Funkce a rekurze

V připadě funkci se spočtená hodnota zapiše do ivalue každe vstupní proměnné. Funkce je pak teoreticky spočetná, ovšem zde se již musí pracovát ne s uzly výrazu, alse s libovolnymi uzly AST. Každy uzel tedy musí mit svou definovanou logiku jeho vypučtu. Obdobně vypada napřiklad vykonání podmíněného výrazu:

```
int execBranch(Branch* node) {
   for (int i = 0; i < node->expressions.size(); i++){
        evaluate(node->expressions[i]);
        if (readValue(node->expressions[i])->i32) {
            return execScope(node->scopes[i]);
        }
   }
   if (node->scopes.size() > node->expressions.size()) {
        return execScope(node->scopes[node->scopes.size() - 1]);
   }
}
```

```
return Err::OK;
}
```

Protože funkce muže obsahovát další volaní funkcí, nemohl jsem si vystačit jen s ivalue, a tak jsem přidal ještě atribut istack. Jak plyne z nazvu, istack měl umožnít ukladat hodnoty všech ostatních volání, každa funkce pak měla atribut istackIdx reprezentující index, ktery by měl byt použít pro získaní hodnot pro jeji kontext.

Funkce ovšem mohlá volát i samu sebe. Musel jsem tedy k atributu istackIdx zavest atribut icnt, ktery by počital každé takové volaní a těm samym sloužíl jako identifikace kontextu. U každé Value se pak nastavoval attribut hasValue na odpovidajicí index, a tak mohla byt provedena kontrola, jestli hodnota byla spočtena v nynejším kontextu. Pokud hodnota nebyla spočtena v dannem kontextu, tak se hodnota překopírovala do cvalue, v opačném připadě se hodnota kopirovla zpět do ivalue.

I když to muže znít složitě, fakticky se jednalo o překopirování všech hodnot do cvalue, což lze udělat před voláním znovu sama sebe. Ve funkci se normalně pracovalo s ivalue a při navratu se hodnoty překopiroválí zpět. Akorta se to provadělo na mistě vypočtu, a tedy se kopirovali jen potřebné proměnné.

Protože ve vysledu by se musel po mimo hlavní časti udrožavat take všechny uzly v interpretueru a neustale je měnít při změnach či refaktoringu, tak jsem se rozhodl se jim moc nezabyvát dokud projek je v aktivním vyvojí. A tedy implementováno je pár uzlu, které slouží k demostrací funkčnosti řešení. Udržováné jsou jen aritmetické funkce, ktere se vnitřně využívaji třeba k vypočtu delek poli.

5.7 Generace C kódu

Překladač AST byl řešen na rozdíl od ostatních modulu abstraktně. Má totíž smysl umět překladat strom do ruzných IR, na rozdíl třeba od parsru, kterých nemá mit smysl několikero, jelikož pracuje vždy s jedním konkretním jazykem.

Překladačem je vlastně instance nasledující jednoduché struktury, která definuje interface:

Zasadními funkcemi jsou printNode a printExpression.

5.7.1 Souborová struktura

Generovát vysledný kod jsem se rozhodl sekvenčně přímo do souboru. Proto jsem potřeboval několík souboru, abych mohl generovát ruzné časti AST do ruzných souboru a ve vysledku je spojit v potřebném pořadí.

Použil jsem nasledující soubory:

- main.c, byl použit jako hlavní soubor, kde byli přidané ostatní osatatní soubory. Zapisovál se kod, ktery bylo možné dat do main funkce.
- functions.h zapisovly se tam definice funkci, aby mohly byt dostupne napřič všemi ostatnimi funkcemi
- functions.c zapisovly se samotné definice funkcí
- typedefs.h zapisovaly se definice struktur a unii.
- variables.h zapisovaly se deklarace definice proměnnych, především globalních.
- foreign_code.c, veškery kod cizích jazyku, viz[]

pořadí....

5.7.2 Globalní rosah platnosti

Protože na rozdíl od C je vstupním bodem počatek souboru, tak i všechny proměnné v něm obsažené by měly byt globalnimi a v připadě definic jsem nemohl je prostě napsat do mainu, ale musel jsem zapsat deklaraci zapsat do souboru variables.h.

Problematickou čatí byla definice statických poli, kde

5.7.3 Vykreslení pole

Nejspiš jedninou netrivialní věci při vykreslení bylo vykreslení vyrazu obsahujicích konkatinaci poli bez využití alokaci.

Implementaci jsem řešíl generaci for smyček. Myšlenka byla nasedující, v nezavislosti kde se vyskytuje oprator konkatinace z pohledu stromové struktury, každy takový vyraz vždy rozšířuje vysledné pole a tedy se chová, řekněme, linearně a každy usek výrazu mezí operatory lze tedy reprezentovát for smyčkou.

Podivejme se na přiklad pro ilustraci.

```
ans = "A" .. (1 + "BB" .. ("C" + 3)) .. "DD"
```

Je-li na levé straně pole řadné velikostí (zajisti to je ukol validtora), tak lze postupně procházet výraz a zapisovát vyraz do for smyčky, kde na levé straně je ans s určitým odsazením a na pravou postupně zapisujeme vyraz. Smyčku uzavřeme pokuď narazíme na operator konkatinace. Pak posuneme offset levé strany o délku dilčího pole, které jsme připojovali a opakujeme.

Tedy, nejprve se nastaví vychozí odsazení na 0 a délka procházení na velikost prvního pole:

```
off0 = 0;
len0 = 1;
for i to len : ans[off0 + i] = "A"[i];
```

Až narazíme na konkatinaci, posuneme odsazení levé strany, nastavime délku a pokračujeme novou smyčkou:

```
off1 = len0;
len1 = 2;
for i to len1 : ans[off1 + i] = 1 + "BB"[i];
```

Opakujeme v dalším kroku:

```
off2 = len1;
len2 = 2;
for i to len2 : ans[off2 + i] = "C"[i] + 3;
```

Opakujeme v posledním kroku:

```
off3 = len2;
len3 = 2;
for i to len3 : ans[off3 + i] = "DD"[i];
```

Vysledný vyraz je schodný s puvodním a dá se generovát sekvenčně. I když ukazano na statickým přikladu, dá se zobecnít na dynamicky.

Prakticky se generace realizuje retrospektivně. Tedy, nejprve je rekurzívně procházen výraz než se narazí na operator konkatinace, načež se vykreslí puvodní čast. To umožňuje získat délku pole před vykreslením aniž by delka byla uložena napříč všemí uzly ve vyrazu.

5.8 Vestavená kompilcae C kodu

Protože jsem chtěl, aby kompilator obsahovál konvenční možnost generace spustitelného souboru, tak jsem dospěl k integrací TCC kompilátoru. Obecně bych mohl použít třeba std::system("gcc build my code pls"), tak jsem jak nechtěl byt zavísly na něčem, co už má uživatel předinstalovany.

Opci by bylo buď distribuovát gcc, nebo i jiny překladač, spolu s kompilatorem, což není šikovný, prtože program pak nejde distribuovat jako zdrojový kod. Lepší cestou by bylo integrovát kompilator do kodu přes přislušnou knihovnu.

GCC

LLVM

TCC jsem vybral proto, že je to malý kus softwaru, ktery vypadal vhodně pro potřebu vestavení, jelikož by nezabral moc místa.

Protože jsem nenašel moc rozumnou informaci o správném použití knihovný pro mojí potřeby, tak popišu použíty postup trochu detailněje.

Samotná instalce knihovný je standardní, tcc obsahuje include a libtce složky, které se musí předát compilatoru jako include path a lib path respektivě a jeden dll soubor. Knihovně potřebné pro samtonou kompilaci C kodu v run-timu jsou pak dosutpné ve složce lib.

Nejprve je nutné vytvořít instancí TCCState, předat potřebné cmd argumenty a nastavít vystupní programu. Zaleží na pořadí!

```
TCCState *state = tcc_new();
tcc_set_options(state, "-ggdb");
tcc_set_output_type(state, TCC_OUTPUT_EXE);

tcc_add_library_path(state, libPath.c_str());
tcc_add_include_path(state, tccIncPath.c_str());
tcc_add_library(state, "gdi32");
...
tcc_add_library(state, "msvcrt");
tcc_add_file(state, "main.c");
tcc_output_file(state, Compiler::outFile);
```

Většína funkcí vrácí chybový stav zohlednění ktereho se v ukazce pominulo. K uvolnění resursu alokovaných tcc new se použije funkce tcc delete.

Ke kompilací C kodu

5.9 Spravá chyb a logovaní

Protože chyby a varování jsou fakticky jedinym komunikačním prostředkem kompilatoru s uživatelem a jejich kvalita je zcela zasadní, potřebovál jsem si vytvořít jednotny a robustní system chyb a definovat pravidla jednotná pravidla pro pro spravu a logovaní chyb.

Aby se docililo jednoznačnosti, definovla jsem si pro sebe pravidlo – chyba musí byt logovaná přímo ve funkcí vyskytu. Jinak se musí řešít jestli použitá funkce vracejicí chybu už provedla logovaní nebo ne. Navíc to umožňuje klasickou propagaci chyby až do mainu, kde se v každe funkcí, buď diky lenosti, nebo nerozhodností, se chyba neošetří a jen se předá dál.

Problemem při logování v mistě chyby muže byt ne vždy uplná znalost kontextu, ovšem, protože postupně parsujeme AST, tak lze připadně retrospektivně podrobnější informací získat. Navíc, vnější funkce muže v připadě nutnosti provest svuj doplňujicí log, pokud to z jejiho kontextu přijde vhodne.

Chybu jsem tedy reprezentoval jednoduše jako negativní integralní hodnotu, kde bezchybový explicitní bezchybový stav je 0. Každa funkce by tedy měla mit navratový typ int a vracet připadnou chybu. Pro každou chybu jsem definoval take standartní chybovou hlášku printf sytaxi. Hlašky byli umistěné v pole a indexovatelné absolutní hodnotou přislušné chyby.

Logovácí system se skladá z pár funkcí a statických hodnot pod namespacem Logger. Za pomoci bitových hodnot lze filtrovát typy hlašek, napřiklad potlačít informace a varování. Logovácí funkce pak umožňovly po mimo hezčího vypisu samotné hlášky take vypsát konkretní místo ve zdrojovém kodě v řadkovém formatě a podtrhnout nutnou část viz obr[].

Protože někdy chyba funkce nemusí známenat kompletní chybu parsingu, někdy se muže parser vydat jednou cestou, zijstít, že to nejdé rozparsovát a zkusít jinou cestu, tak je nutné umět se vyhnout logování. Pro takový to připad je v rámci Loggeru dostupná proměnná mute, kde každe vlákno muže nastavít vlastní bit v zavislostí na svém id. Prozatím ale funguje jen jako bool hodnotá, protože multithreading v aplikaci nebyl řešen.

Ovšem, protože chyba samotného parsru vlastně vede ke konci kompilace, tak generace chybové zpravy muže byt obecně složítá, a tedy i když řešení skrz samotný Logger je číste, tak neni optimalní. Lepší by bylo předavát potřebnou informací skrz vstupní proměnné funkce, v ideale zavést nějaky context a předavat obecně potřebné proměnné skrz něho.

6 Závěr

Seznam literatury

- [1] WIKIPEDIA. Intermediate representation [online]. 2025. [cit. 2025-04-04]. Dostupné z: https://en.wikipedia.org/wiki/Intermediate_representation.
- [2] LATTNER, Chris. LLVM: The Architecture of Open Source Applications (Volume 1) [online]. 2011. [cit. 2025-04-04]. Dostupné z: https://aosabook.org/en/v1/llvm.html.
- [3] MERRILL, Jason. GENERIC and GIMPLE: A New Tree Representation for Entire Functions. In: *Proceedings of the GCC Developers Summit.* Red Hat, Inc., 2003.
- [4] WIKIPEDIA. Java bytecode [online]. 2025. [cit. 2025-04-04]. Dostupné z: https://en.wikipedia.org/wiki/Java bytecode.
- [5] WIKIPEDIA. Common Intermediate Language [online]. 2025. [cit. 2025-04-04]. Dostupné z: https://cs.wikipedia.org/wiki/Common_Intermediate_Language.
- [6] GRUNE, Dick; REEUWIJK, Kees van; BAL, Henri E.; JACOBS, Ceriel J.H.; LANGENDOEN, Koen G. *Modern Compiler Design*. Second Edition. Springer, 2012. ISBN 978-1-4614-1202-3. Dostupné z DOI: 10.1007/978-1-4614-1202-3.
- [7] COOPER, Keith D.; TORCZON, Linda. *Engineering a Compiler*. Second Edition. Morgan Kaufmann, 2012. ISBN 978-0-12-088478-0.
- [8] JOHNSON, Stephen C. Yacc: Yet Another Compiler-Compiler. 1975. Tech. zpr., 32. Bell Laboratories.
- [9] PARR, Terence. Preface. In: *The Definitive ANTLR 4 Reference*. Pragmatic Bookshelf, 2013, relevant preface page numbers (if any). ISBN 978-1-934356-99-9. Dated 2012.
- [10] JIANG, Tao; LI, Ming; RAVIKUMAR, Bala; REGAN, Kenneth W. Formal Grammars and Languages. In: ATALLAH, Mikhail J. (ed.). *Algorithms and Theory of Computation Handbook*. CRC Press, 1998. ISBN 978-0-8493-2649-3.
- [11] MICROSOFT. Announcing WebAssembly Language Support in VS Code [online]. [cit. 2025-04-05]. Dostupné z: https://code.visualstudio.com/blogs/2024/05/08/wasm.
- [12] MICROSOFT. Extension Anatomy Visual Studio Code [online]. [cit. 2025-04-05]. Dostupné z: https://code.visualstudio.com/api/get-started/extension-anatomy.
- [13] NEOVIM. Neovim documentation: lua [online]. [cit. 2025-04-05]. Dostupné z: https://neovim.io/doc/user/lua.html.

- [14] MICROSOFT. Syntax Highlight Guide Visual Studio Code [online]. [cit. 2025-04-05]. Dostupné z: https://code.visualstudio.com/api/language-extensions/syntax-highlight-guide.
- [15] VIM DOCUMENTATION PROJECT. Vim documentation: syntax [online]. [cit. 2025-04-05]. Dostupné z: https://vimdoc.sourceforge.net/htmldoc/syntax.html.
- [16] NEOVIM. Neovim documentation: lsp [online]. [cit. 2025-04-05]. Dostupné z: https://neovim.io/doc/user/lsp.html.
- [17] MICROSOFT. Language Server Extension Guide Visual Studio Code [online]. [cit. 2025-04-05]. Dostupné z: https://code.visualstudio.com/api/language-extensions/language-server-extension-guide.
- [18] MATSU. Shiki: A beautiful syntax highlighter for the web. [online]. [cit. 2025-04-05]. Dostupné z: https://shiki.matsu.io/.
- [19] COOLWANGLU. vim.js: JavaScript port of Vim [online]. [cit. 2025-04-05]. Dostupné z: https://github.com/coolwanglu/vim.js.
- [20] LLVM PROJECT. Source Level Debugging with LLVM [online]. [cit. 2025-04-05]. Dostupné z: https://llvm.org/docs/SourceLevelDebugging.html.
- [21] MICROSOFT. Visual Studio Debugger Documentation [online]. [B.r.]. [cit. 2025-04-05]. Dostupné z: https://learn.microsoft.com/en-us/visualstudio/debugger/.
- [22] EAGER, Michael J. Introduction to the DWARF Debugging Format. 2012. Often found online as a PDF document.
- [23] MICROSOFT. #line Directive (C/C++) [online]. [cit. 2025-04-05]. Dostupné z: https://learn.microsoft.com/en-us/cpp/preprocessor/hash-line-directive-c-cpp?view=msvc-170.
- [24] PROJECT, ANTLR. ANTLR Parser Generator. [B.r.]. Dostupné také z: https://www.antlr.org/download.html. Accessed April 4, 2025.